ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH

TRƯỜNG ĐẠI HỌC BÁCH KHOA

KHOA KHOA HỌC VÀ KỸ THUẬT MÁY TÍNH

BÁO CÁO BÀI TẬP LỚN

Môn: Kho dữ liệu và Hệ hỗ trợ Quyết định (CO4031)

Kho dữ liệu phân tích bán hàng – giao hàng và hệ hỗ trợ quyết định cải thiện sự hài lòng khách hàng cho sàn TMĐT Olist

Giảng viên hướng dẫn:	Đỗ Thanh Thái
Nhóm:	**[TODO]** số nhóm
Học kỳ:	261 (2026–2027)

Họ và tên	**MSSV**	**Đóng góp**
[TODO] Thành viên A	**[TODO]**	**[TODO]** %
[TODO] Thành viên B	**[TODO]**	**[TODO]** %
[TODO] Thành viên C	**[TODO]**	**[TODO]** %

Mã nguồn: `https://github.com/taita2005/co4031-olist-dw-dss`
Dữ liệu: **[TODO]** link Google Drive (nguồn gốc: Kaggle, Olist)
Video thuyết trình: **[TODO]** link, nếu thuyết trình qua video

TP. Hồ Chí Minh, tháng 11/2026

Mục lục

Thành viên và phân công **3**

1 Giới thiệu bài toán **4**
1.1 Bối cảnh nghiệp vụ 4
1.2 Vấn đề 4
1.3 Người ra quyết định và loại quyết định 4
1.4 Câu hỏi nghiệp vụ 4
1.5 Dữ liệu 5
1.6 Giải pháp và tính năng 7
1.7 Phương pháp phát triển 8

2 Thiết kế kho dữ liệu **9**
2.1 Bốn đặc tính Inmon trong project 9
2.2 Mức khái niệm: data cube 9
2.3 Mức logic: fact constellation 9
2.4 Các bảng dimension 10
2.5 Các bảng fact 11
2.6 Quy trình ETL 12
2.7 Thiết kế vật lý và metadata 15

3 Xây dựng Backend và Frontend **16**
3.1 Kiến trúc ba tầng 16
3.2 Công nghệ 17
3.3 Backend: kết quả ETL 18
3.4 Backend: kiểm soát chất lượng dữ liệu 19
3.5 Backend: OLAP theo kiến trúc ROLAP 20
3.6 Frontend: dashboard Streamlit 20
3.6.1 Trang OLAP 21
3.6.2 Trang Home 24
3.6.3 Trang Delivery 25
3.6.4 Trang Data Quality 29

4 Hệ thống hỗ trợ ra quyết định **31**
4.1 Cơ sở lý thuyết 31
4.2 Phân loại, kiến trúc và quá trình ra quyết định 31
4.3 Mô hình cây quyết định 32

4.3.1 Dữ liệu và thuộc tính . . . 32
4.3.2 Thuật toán, cấu hình và chọn tham số . . . 33
4.3.3 Ví dụ tính information gain (theo công thức slide Ch.5) . . . 34
4.3.4 Kết quả đánh giá trên tập test (19.165 đơn) . . . 35
4.3.5 Luật IF-THEN (15 lá, sắp theo rủi ro) . . . 36
4.4 Mô hình rủi ro và các biến . . . 37
4.5 Các công cụ ra quyết định . . . 38
4.5.1 What-if analysis . . . 38
4.5.2 Sensitivity analysis . . . 39
4.5.3 Goal seeking . . . 40
4.5.4 Xếp hạng ưu tiên (Choice) . . . 40
4.5.5 Tối ưu phân bổ ngân sách (Choice — mathematical programming) . . . 41
4.6 Đề xuất cho nhà quản lý (Implementation) . . . 48

5 Đánh giá **50**
5.1 Mức độ đáp ứng yêu cầu bài tập lớn . . . 50
5.2 Hạn chế . . . 52
5.3 Hướng phát triển . . . 52
5.4 Ví dụ thực tế về DW & DSS (L.O.1.3) . . . 53
5.5 Kết luận . . . 53

A Hướng dẫn cài đặt và chạy **55**

B Cấu trúc mã nguồn **56**

C Danh sách đầy đủ 43 kiểm tra chất lượng **57**

D Thay đổi so với proposal ban đầu **59**

E Danh sách hình cần chụp **60**

Thành viên và phân công

Thành viên	MSSV	Vai trò	Công việc cụ thể	Phần thuyết trình	Đóng góp
[TODO] A	**[TODO]**	Phát triển hệ thống	Hiện thực mã nguồn: DW, ETL, OLAP dashboard, DSS; review chéo báo cáo	Chương 1–2	**[TODO]** %
[TODO] B	**[TODO]**	Review DW / OLAP, viết báo cáo	Review `src/sql`, `src/etl`, các trang Home / OLAP / Delivery; viết Chương 2–3	Chương 3	**[TODO]** %
[TODO] C	**[TODO]**	Review DSS, viết báo cáo, slide	Review `src/dss`, trang DSS; viết Chương 4–5; làm slide	Chương 4–5	**[TODO]** %

[TODO] Cập nhật vai trò cho đúng thực tế: hai bạn đã đóng góp code qua PR #1 (tối ưu ngân sách) và PR #2 (Docker Compose + Metabase).

Chương 1. Giới thiệu bài toán

1.1 Bối cảnh nghiệp vụ

Olist là sàn thương mại điện tử của Brazil. Sàn kết nối các người bán nhỏ với khách hàng trên toàn quốc, còn việc giao hàng do các đơn vị vận chuyển đảm nhận. Sau khi nhận hàng, khách hàng chấm điểm đơn hàng từ 1 đến 5 sao. Điểm thấp ảnh hưởng trực tiếp đến uy tín của sàn và của người bán.

1.2 Vấn đề

Trong dữ liệu 2016–2018, **12,81%** đơn đã giao bị đánh giá 1–2 sao (gọi là *review xấu*). Phân tích ban đầu cho thấy giao trễ là nghi phạm chính (Bảng 1.1): đơn giao trễ có tỷ lệ review xấu gấp gần 7 lần đơn giao đúng hạn.

Bảng 1.1: Tỷ lệ review xấu theo tình trạng giao hàng

Nhóm đơn đã giao	Số đơn	Điểm review TB	Tỷ lệ review xấu
Giao đúng hạn hoặc sớm	89.936	4,290	9,27%
Giao trễ (sau ngày dự kiến)	6.534	2,270	62,42%
Tổng	**96.470**	**4,156**	**12,81%**

(Gợi ý biểu đồ: cột đôi)

1.3 Người ra quyết định và loại quyết định

- **Người ra quyết định:** quản lý vận hành / logistics của sàn.
- **Loại quyết định:** *semi-structured*. Dữ liệu cho biết hiện trạng, nhưng chọn nơi đầu tư và mức đầu tư vẫn cần phán đoán của quản lý. Theo slide Ch.6, DSS hỗ trợ các quyết định semi-structured và unstructured.

1.4 Câu hỏi nghiệp vụ

Câu hỏi phân tích (kho dữ liệu và OLAP trả lời, Chương 2 và 3):

1. Doanh thu và số đơn biến động thế nào theo thời gian, vùng, danh mục?

2. Tỷ lệ giao trễ và thời gian giao trung bình theo bang và danh mục?
3. Điểm review thay đổi thế nào theo mức độ trễ?

Câu hỏi quyết định (DSS trả lời, Chương 4):

1. Yếu tố nào dẫn đến review xấu?
2. *What-if:* nếu giảm X% đơn trễ (hoặc rút ngắn N ngày giao) ở một bang hay danh mục, tỷ lệ review xấu giảm bao nhiêu?
3. *Goal seeking:* cần giảm bao nhiêu % đơn trễ để tỷ lệ review xấu không vượt mục tiêu T%?
4. Nên ưu tiên đầu tư logistics cho bang hay danh mục nào?
5. *Tối ưu:* với một ngân sách giới hạn, nên chọn những bang nào và giảm bao nhiêu % đơn trễ ở mỗi bang để tránh được nhiều review xấu nhất? Thứ tự ưu tiên đó có còn đúng khi giả định chi phí thay đổi không? **Đây là câu hỏi quyết định chính**, được trả lời ở Mục 4.5.5.

1.5 Dữ liệu

Nguồn: *Brazilian E-Commerce Public Dataset by Olist*, Kaggle. Đây là dữ liệu mở (thoả §3.1b của đề), gồm đơn hàng thật đã được ẩn danh, với ngày mua từ 2016-09-04 đến 2018-10-17.

Bảng 1.2: Các file dữ liệu nguồn

File CSV	Số dòng	Nội dung	Dùng trong project
olist_orders_dataset	99.441	Đơn hàng: khách, trạng thái, 5 mốc thời gian	Có
olist_order_items_dataset	112.650	Sản phẩm trong đơn: giá, phí ship, người bán	Có
olist_order_payments_dataset	103.886	Thanh toán (một đơn có thể có nhiều lần thanh toán)	Nạp vào staging, chưa dùng trong DW
olist_order_reviews_dataset	99.224	Đánh giá 1–5 sao	Có
olist_customers_dataset	99.441	Khách hàng: zip, thành phố, bang	Có
olist_sellers_dataset	3.095	Người bán: zip, thành phố, bang	Có
olist_products_dataset	32.951	Sản phẩm: danh mục, kích thước, khối lượng	Có
product_category_name_translation	71	Dịch tên danh mục Bồ Đào Nha → Anh	Có
olist_geolocation_dataset	1.000.163	Toạ độ theo zip code	Không cần cho bài toán

Quan hệ giữa các bảng nguồn: `orders` là bảng trung tâm.

- `order_items`, `order_payments`, `order_reviews` nối với `orders` qua `order_id`.
- `order_items` nối với `products` và `sellers`.
- `orders` nối với `customers` qua `customer_id`.

[HÌNH] ERD dữ liệu nguồn

Bảng 1.3: Trạng thái đơn hàng

order_status	Số đơn	Tỷ lệ
delivered	96.478	97,02%
shipped	1.107	1,11%
canceled	625	0,63%
unavailable	609	0,61%
invoiced	314	0,32%
processing	301	0,30%
created	5	0,01%
approved	2	0,00%

Bảng 1.4: Phương thức thanh toán

payment_type	Số lượt	Giá trị (R$)
credit_card	76.795	12.542.084,19
boleto	19.784	2.869.361,27
voucher	5.775	379.436,87
debit_card	1.529	217.989,79
not_defined	3	0,00

Khảo sát chất lượng dữ liệu (data profiling)

Bảng 1.5 là cơ sở cho các quy tắc làm sạch trong ETL (Mục 2.6).

Bảng 1.5: Kết quả khảo sát chất lượng dữ liệu

#	Vấn đề	Số liệu	Cách xử lý
1	`customer_id` được sinh mới cho mỗi đơn, không định danh khách thật	99.441 customer_id ứng với 96.096 `customer_unique_id`; 2.997 khách mua >1 lần	Dimension khách hàng dùng `customer_unique_id`
2	Review trùng	99.224 dòng, 98.410 review_id, 98.673 đơn; 547 đơn có >1 review	Mỗi đơn giữ review trả lời gần nhất
3	Sản phẩm thiếu danh mục	610 sản phẩm	Gán `unknown`
4	Danh mục thiếu bản dịch	2 danh mục (`pc_gamer`, `portateis_cozinha_e_preparadores_de_alimentos`)	Bổ sung bản dịch thủ công

#	Vấn đề	Số liệu	Cách xử lý
5	Sản phẩm thiếu khối lượng / kích thước	2 sản phẩm	Để NULL
6	Đơn chưa có ngày giao	2.965 đơn; trong đó 8 đơn trạng thái `delivered`	Loại khỏi `fact_delivery`
7	Một đơn có nhiều lần thanh toán	2.961 đơn	Không cộng thanh toán theo item (tránh đếm trùng)
8	Một đơn có nhiều người bán	1.278 đơn	Lưu `n_sellers`; chọn "người bán chính"
9	File dịch danh mục có ký tự BOM đầu file	–	Đọc bằng `utf-8-sig`
10	Zip code có số 0 đầu (vd. `01037`)	–	Lưu dạng TEXT
11	Comment review chứa xuống dòng	–	Dùng CSV parser thật (`COPY … CSV`, `csv.reader`)
12	Geolocation không duy nhất theo zip	1.000.163 dòng / 19.015 zip	Không nạp

1.6 Giải pháp và tính năng

Nhóm xây dựng một **data mart chủ đề Bán hàng & Giao hàng** theo kiến trúc ba tầng (Mục 3.1). Phía trên data mart là một dashboard OLAP và một DSS.

Bảng 1.6: Tính năng và câu hỏi nghiệp vụ tương ứng

Tính năng	Nơi hiện thực	Trả lời câu hỏi
ETL tự động CSV → staging → DW, ghi metadata	`src/etl/run_etl.py`, `src/sql/*.sql`	Nền tảng dữ liệu tích hợp
Kiểm tra hợp đồng nguồn và 43 kiểm tra chất lượng sau mỗi lần nạp	`src/etl/contracts.py`, `src/sql/05_checks.sql`, trang Data Quality	Độ tin cậy của dữ liệu
Dashboard KPI và xu hướng theo tháng	Trang Home	Phân tích 1
OLAP Explorer: roll-up, drill-down, slice, dice, pivot trên 2 fact	Trang OLAP	Phân tích 1, 2
Phân tích giao hàng và review theo mức trễ, bang, danh mục	Trang Delivery	Phân tích 2, 3
Cây quyết định và luật IF-THEN về review xấu	Trang DSS, tab 1	Quyết định 1
Xếp hạng ưu tiên bang / danh mục và đề xuất hành động	Trang DSS, tab 2	Quyết định 4
What-if (2 biến quyết định) và sensitivity analysis	Trang DSS, tab 3	Quyết định 2
Goal seeking	Trang DSS, tab 4	Quyết định 3
Tối ưu phân bổ ngân sách và phân tích độ vững theo giả định chi phí	Trang DSS, tab 5	Quyết định 5

1.7 Phương pháp phát triển

Nhóm phát triển theo *prototyping* (iterative / evolutionary, RAD). Theo slide Ch.8, đây là cách DSS thường được phát triển. Vòng 1 làm kho dữ liệu và dashboard tối thiểu, vòng 2 thêm DSS, vòng 3 thêm kiểm soát chất lượng dữ liệu, tối ưu ngân sách và hoàn thiện theo góp ý review.

Chương 2. Thiết kế kho dữ liệu

Theo Inmon, kho dữ liệu là *"a subject-oriented, integrated, time-variant, and non-volatile collection of data in support of management's decision-making process"*. Thiết kế đi qua các mức khái niệm (data cube) → logic (star / snowflake / fact constellation) → vật lý. Hai quyết định thiết kế quan trọng nhất là **granularity** và **partitioning** (slide Ch.2).

2.1 Bốn đặc tính Inmon trong project

Đặc tính	Thể hiện
Subject-oriented	Chỉ tập trung vào chủ đề bán hàng – giao hàng – hài lòng
Integrated	Gộp 8 nguồn và chuẩn hoá: khách hàng thật, danh mục tiếng Anh, vùng địa lý, khoá ngày thống nhất
Time-variant	Chiều `dim_date` (2016–2018); mọi fact đều gắn khoá ngày
Non-volatile	Kho dữ liệu chỉ được nạp (load), không bị cập nhật bởi giao dịch

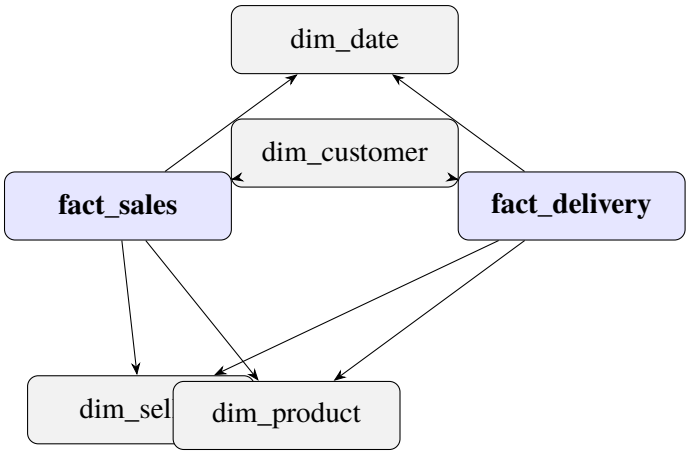
Hướng tiếp cận: *bottom-up (Kimball)*, xây trước một data mart cho một chủ đề (slide Ch.3).

2.2 Mức khái niệm: data cube

Thành phần	Nội dung
Chiều (dimensions)	Thời gian, Khách hàng (địa lý), Người bán (địa lý), Sản phẩm (danh mục)
Measures – khối Bán hàng	Doanh thu (price), phí vận chuyển, số sản phẩm, số đơn
Measures – khối Giao hàng	Số ngày giao, số ngày trễ, có trễ không, điểm review, có review xấu không

2.3 Mức logic: fact constellation

Schema gồm **2 bảng fact dùng chung 4 dimension**. Đây là *fact constellation* (galaxy schema), giống ví dụ *"sales and shipping data warehouse"* trong slide Ch.3.



Hình 2.1: Schema fact constellation: 2 fact dùng chung 4 dimension. `fact_delivery` dùng `dim_date` 2 lần (ngày mua, ngày giao).

> **[HÌNH]** Schema chi tiết (vẽ bằng dbdiagram.io hoặc chụp từ DBeaver)

Grain (granularity)

Fact	Grain (1 dòng =)	Lý do
`fact_sales`	1 sản phẩm trong 1 đơn hàng	Mức chi tiết nhất của doanh thu; phân tích được theo sản phẩm và người bán
`fact_delivery`	1 đơn hàng **đã giao**	Ngày giao và review thuộc về **cả đơn**, không thuộc từng sản phẩm

Vì sao không gộp thành 1 fact? Nếu đặt review vào `fact_sales`, một đơn có 3 sản phẩm sẽ lặp review 3 lần. Khi đó điểm trung bình và tỷ lệ review xấu bị tính sai do đếm trùng. Đây chính là vấn đề granularity nêu trong slide Ch.2.

2.4 Các bảng dimension

Mọi dimension dùng **surrogate key** kiểu số nguyên tự tăng (Kimball).

Dimension	Khoá	Thuộc tính	Hierarchy	Số dòng
`dim_date`	date_key (yyyymmdd)	full_date, day, month, month_name, quarter, year, year_month, weekday, is_weekend	year > quarter > month > day	1.096
`dim_customer`	customer_key	customer_unique_id, zip_code_prefix, city, state, region	region > state > city	96.096
`dim_seller`	seller_key	seller_id, zip_code_prefix, city, state, region	region > state > city	3.095
`dim_product`	product_key	product_id, category_pt, category_en, photos_qty, weight_g, volume_cm3	category > product	32.951

Bảng 2.1: Ánh xạ bang → vùng (5 vùng hành chính của Brazil)

Vùng	Các bang
North	AC, AP, AM, PA, RO, RR, TO
Northeast	AL, BA, CE, MA, PB, PE, PI, RN, SE
Central-West	DF, GO, MT, MS
Southeast	ES, MG, RJ, SP
South	PR, RS, SC

2.5 Các bảng fact

Bảng 2.2: `fact_sales` (112.650 dòng)

Cột	Loại	Ý nghĩa
purchase_date_key, customer_key, seller_key, product_key	FK	Khoá tới 4 dimension
order_id, order_item_id, order_status	Degenerate dimension	Thông tin đơn hàng, không cần bảng riêng
price	Measure, additive	Giá sản phẩm
freight_value	Measure, additive	Phí vận chuyển
total_value	Measure, additive	price + freight_value

Bảng 2.3: `fact_delivery` (96.470 dòng)

Cột	Loại	Ý nghĩa
order_id	Degenerate, PK	Mã đơn
purchase_date_key, delivered_date_key	FK → dim_date	Dùng chiều ngày 2 lần (ngày mua, ngày giao)
customer_key	FK	Khách hàng
seller_key, product_key	FK	Người bán và sản phẩm của **item chính** (item giá cao nhất trong đơn)
n_items, n_sellers	Measure, additive	Số sản phẩm, số người bán trong đơn
order_value, freight_total	Measure, additive	Tổng giá, tổng phí ship
delivery_days	Measure	Số ngày từ lúc mua đến lúc giao
estimated_days	Measure	Số ngày từ lúc mua đến ngày giao dự kiến
delay_days	Measure	Ngày giao − ngày dự kiến (> 0 là trễ)
is_late	Measure 0/1	1 nếu giao trễ
review_score	Measure	Điểm 1–5 (NULL nếu đơn không có review)
is_bad_review	Measure 0/1	1 nếu điểm ≤ 2

Phân loại measure: tổng tiền, số sản phẩm, số đơn đã giao là **additive** (cộng dồn được). Trung bình, tỷ lệ và số đơn *distinct* là **non-additive**: không lấy tổng của các nhóm con được, phải tính lại từ fact. Trang OLAP thể hiện rõ sự khác biệt này (Mục 3.6.1).

2.6 Quy trình ETL

Theo slide Ch.2: *Extract* lấy dữ liệu mà không làm gián đoạn hệ thống nguồn; *Transform* gồm data cleansing, data mapping và business rules application; *Load* có thể nạp incremental hoặc full refresh. Dữ liệu đi qua **data staging area** (slide Ch.1).

Toàn bộ ETL chạy bằng **1 lệnh** `python src/etl/run_etl.py`, mất khoảng 12 giây (gồm cả bước kiểm tra hợp đồng nguồn và kiểm tra chất lượng).

[HÌNH] Luồng ETL: CSV → staging → dw → meta

Bảng 2.4: Các bước ETL

Bước	File	Việc làm
0. Kiểm tra nguồn	`contracts.py`	Đọc từng CSV bằng CSV parser trước khi nạp. Thiếu file hoặc header sai thì **dừng hẳn**, chưa động vào CSDL. Vi phạm về giá trị được ghi thành check (Mục 3.4)
1. Extract	`01_staging.sql`, `run_etl.py`	Tạo schema `staging`, mỗi CSV một bảng, **mọi cột kiểu TEXT** (giữ nguyên nguồn); nạp hàng loạt bằng `COPY … FORMAT csv`
2. Tạo schema DW	`02_dw_schema.sql`	Xoá và tạo lại schema `dw`: 4 dimension, 2 fact, index, partition; tạo `meta.etl_log` nếu chưa có
3. Transform + Load	`03_transform_load.sql`	Làm sạch, ánh xạ, áp quy tắc nghiệp vụ, nạp vào dimension rồi fact
4. Tổng hợp sẵn	`04_olap_views.sql`	Tạo 3 materialized view
5. Metadata	`run_etl.py`	Ghi số dòng nguồn → đích của từng bảng vào `meta.etl_log`
6. Kiểm tra chất lượng	`05_checks.sql`	Ghi 27 kiểm tra trên DW vào `meta.check_result`. Cả 6 bước chạy trong **1 transaction**: lỗi thì rollback toàn bộ. Có check không đạt thì lệnh trả mã lỗi 1

Bảng 2.5: Các quy tắc Transform (đều nằm trong `03_transform_load.sql`)

Nhóm (slide Ch.2)	Quy tắc
Data cleansing	Đơn có nhiều review → giữ review có `review_answer_timestamp` mới nhất; danh mục rỗng → `unknown`; bổ sung bản dịch cho 2 danh mục thiếu; ép kiểu TEXT → DATE / NUMERIC / INTEGER, chuỗi rỗng → NULL
Data mapping	Danh mục PT → EN; timestamp → `date_key` (yyyymmdd); bang → vùng; zip giữ dạng TEXT
Business rules	Khách hàng thật = `customer_unique_id`, giữ địa chỉ của đơn gần nhất; `fact_delivery` chỉ gồm đơn `delivered` có ngày giao; `is_late = 1` khi ngày giao $>$ ngày dự kiến; review xấu = điểm ≤ 2; item chính = item giá cao nhất (hoà thì lấy `order_item_id` nhỏ nhất); `fact_sales` giữ mọi trạng thái đơn, các phân tích doanh thu loại `canceled` / `unavailable`
Attribute construction (slide Ch.2)	`delivery_days`, `estimated_days`, `delay_days`, `is_late`, `is_bad_review`, `n_items`, `n_sellers`, `volume_cm3` = dài $\times$ rộng $\times$ cao, `region`
Discretization (tầng phân tích)	Nhóm mức trễ: sớm $>$ 7 ngày / sớm 1–7 / đúng ngày / trễ 1–3 / 4–7 / 8–14 / $>$ 14 ngày

Load: dùng *full refresh*: mỗi lần chạy, `staging` và `dw` được xoá và nạp lại. Cách này đơn giản và chạy lại bao nhiêu lần cũng cho cùng kết quả. *Incremental load* là hướng phát triển.

2.7 Thiết kế vật lý và metadata

Kỹ thuật	Hiện thực	Mục đích
Surrogate key	`SERIAL` cho dim_customer / seller / product; `date_key` dạng yyyymmdd	Khoá gọn, độc lập với khoá nguồn
Partitioning theo thời gian (slide Ch.1)	`fact_sales` có `PARTITION BY RANGE (purchase_date_key)`, 3 partition 2016 / 2017 / 2018	Truy vấn theo năm chỉ quét partition cần thiết
Index	Index trên các FK của 2 fact	Tăng tốc join / slice / dice
Materialized views	`mv_monthly_kpi`, `mv_sales_cube`, `mv_delivery_by_state`	Tổng hợp sẵn (ROLAP, Mục 3.5)
Metadata (slide Ch.2: "history of extracts")	`meta.etl_log(run_id, step, table_name, source_rows, loaded_rows, note)` đặt ở schema riêng nên **không bị xoá** khi full refresh	Truy vết từng lần nạp
Metadata chất lượng	`meta.check_result(run_id, category, check_name, expected, actual, passed)`	Lưu kết quả kiểm tra của từng lần nạp
Lineage dữ liệu → mô hình	`models/metrics.json` lưu `etl_run_id` của lần ETL dùng để train	Trang Data Quality cảnh báo khi mô hình được train từ dữ liệu cũ

Bảng 2.6: Số dòng mỗi partition

Partition	Số dòng
fact_sales_2016	370
fact_sales_2017	50.864
fact_sales_2018	61.416
Tổng	**112.650**

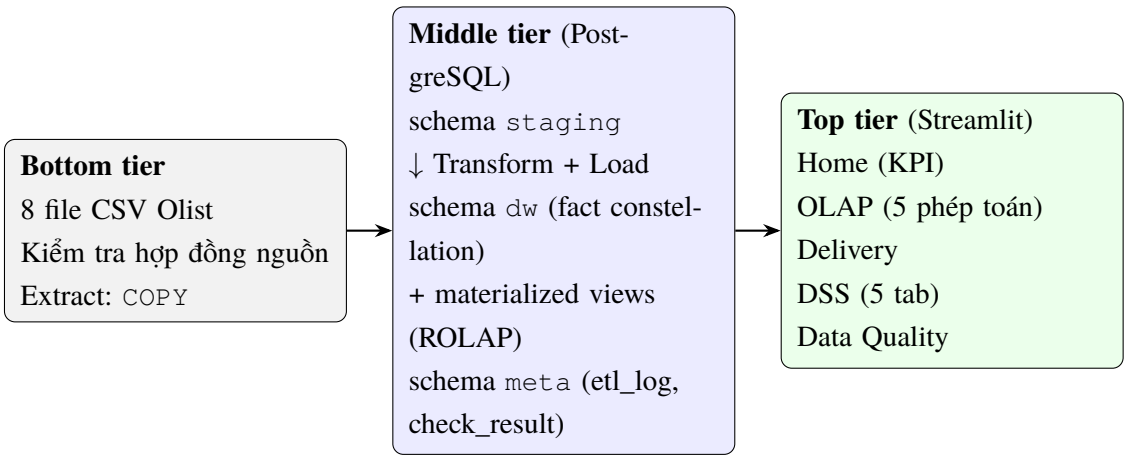
Bảng 2.7: Dung lượng trên đĩa (gồm index)

Bảng	Dung lượng
fact_delivery	24 MB
dim_customer	17 MB
fact_sales_2018 / 2017 / 2016	14 MB / 11 MB / 168 kB
dim_product	6,8 MB
dim_seller	680 kB
dim_date	144 kB
mv_sales_cube / mv_monthly_kpi / mv_delivery_by_state	136 / 16 / 16 kB

Chương 3. Xây dựng Backend và Frontend

3.1 Kiến trúc ba tầng

Hệ thống theo **kiến trúc ba tầng** (slide Ch.2–3). Phía trên data mart là dashboard OLAP và DSS.



Hình 3.1: Kiến trúc ba tầng của hệ thống

[HÌNH] Vẽ lại sơ đồ kiến trúc (nếu cần đẹp hơn)

3.2 Công nghệ

Thành phần	Công nghệ	Ghi chú
CSDL / DW	PostgreSQL 16	Partitioning, materialized view, `GROUP BY CUBE`
ETL	Python 3.12 (psycopg2, SQLAlchemy) + SQL	Python điều phối, SQL biến đổi
Mô hình DSS	scikit-learn 1.5, pandas	`DecisionTreeClassifier` (entropy)
Tối ưu	SciPy (`milp`, solver HiGHS)	Giải chính xác bài toán phân bổ ngân sách
Giao diện	Streamlit 1.39, Plotly	Web app nhiều trang
Kiểm thử	pytest	102 test: unit và kiểm tra trên CSDL thật
Môi trường	micromamba (cục bộ trong project)	Cài Python + PostgreSQL bằng 1 lệnh, không đụng hệ thống
Tuỳ chọn	Docker Compose, Metabase	Chạy toàn bộ stack bằng container, kèm 3 dashboard Metabase; không dùng cho số liệu trong báo cáo này

3.3 Backend: kết quả ETL

Bảng 3.1: Nội dung `meta.etl_log` của lần chạy gần nhất

Bước	Bảng	Dòng nguồn	Dòng nạp	Ghi chú
extract	staging.orders	99.441	99.441	
extract	staging.order_items	112.650	112.650	
extract	staging.order_payments	103.886	103.886	
extract	staging.order_reviews	99.224	99.224	
extract	staging.customers	99.441	99.441	
extract	staging.sellers	3.095	3.095	
extract	staging.products	32.951	32.951	
extract	staging.category_translation	71	71	
load	dw.dim_date	–	1.096	Sinh lịch 2016–2018
load	dw.dim_customer	99.441	96.096	Gộp về customer_unique_id
load	dw.dim_seller	3.095	3.095	
load	dw.dim_product	32.951	32.951	
load	dw.fact_sales	112.650	112.650	
load	dw.fact_delivery	99.441	96.470	Chỉ đơn delivered có ngày giao

Bảng 3.2: Kiểm tra tính đúng đắn của ETL

Kiểm tra	Kết quả
Số dòng staging = số dòng CSV (đếm bằng CSV parser)	Khớp cả 8 file
`SUM(price)` staging = `SUM(price)` `dw.fact_sales`	13.591.643,70 = 13.591.643,70
`fact_delivery` = số đơn delivered − số đơn delivered thiếu ngày giao	96.478 − 8 = 96.470
Chạy lại ETL lần 2	Cùng số dòng; `etl_log` có thêm 1 lượt chạy
Thời gian chạy	∼5 giây cho riêng phần nạp (4,6–4,9 s, đo ngày 02/11); ∼12 giây khi gồm cả kiểm tra hợp đồng nguồn và kiểm tra chất lượng (12,3 s, đo ngày 14/11)

3.4 Backend: kiểm soát chất lượng dữ liệu

Mỗi lần chạy ETL đều tự kiểm tra lại dữ liệu và lưu kết quả vào `meta.check_result`. Nhờ vậy, người dùng dashboard và mô hình DSS biết dữ liệu có đáng tin hay không mà không cần kiểm tra tay.

Nguyên tắc. Giá trị kỳ vọng của mỗi kiểm tra được **tính lại độc lập từ staging**, không dùng lại logic transform. Nếu tính kỳ vọng bằng chính logic transform thì một lỗi trong transform sẽ tự "khớp" với chính nó và không bị phát hiện.

Bảng 3.3: Hai lớp kiểm tra

Lớp	File	Khi nào chạy	Nội dung
Hợp đồng nguồn (*source contract*)	`src/etl/contracts.py`	Trước khi nạp	Mỗi CSV phải có đúng header như mô tả; khoá có mặt và không trùng; số và thời gian đọc được; điểm review 1–5; bang là mã UF 2 chữ; zip đủ 5 chữ số
Kiểm tra trên DW	`src/sql/05_checks.sql`	Sau khi nạp	Grain, đối chiếu staging $\leftrightarrow$ DW, miền giá trị, độ phủ, tổng của materialized view

Bảng 3.4: Kết quả kiểm tra lần chạy 14/11/2026: 43/43 đạt (danh sách đầy đủ ở Phụ lục C)

Nhóm	Số KT	Ví dụ
source	16	Mỗi file trong 8 CSV: không vi phạm hợp đồng; số dòng CSV = số dòng staging
grain	3	Không trùng (order_id, order_item_id) trong fact_sales; không trùng order_id trong fact_delivery; không trùng customer_unique_id
reconciliation	10	Số dòng, SUM(price), SUM(freight_value) giữa staging và fact_sales; số đơn trễ; số đơn có review
domain	7	review_score trong 1..5; is_bad_review nhất quán với điểm ≤ 2; delay_days = delivery_days $-$ estimated_days; total_value = price + freight_value
coverage	3	Mọi ngày mua / giao nằm trong dim_date; mọi danh mục có tên tiếng Anh; mọi bang có vùng
aggregate	4	Tổng của mv_sales_cube, mv_monthly_kpi, mv_delivery_by_state khớp với fact; các tỷ lệ nằm trong [0, 1]
Tổng	**43**	

Kiểm thử tự động. Thư mục `tests/` có 102 test (pytest), gồm unit test và test chạy trên CSDL thật. Với mỗi quy tắc nghiệp vụ, `tests/test_etl_checks.py` cố tình làm hỏng dữ liệu để xác nhận kiểm tra tương ứng báo lỗi. Lần chạy 14/11: **100 test đạt, 2 test bỏ qua**. Một test cần ETL chạy 2 lần; test còn lại chỉ chạy trong môi trường Docker.

3.5 Backend: OLAP theo kiến trúc ROLAP

Theo slide Ch.3, các phép toán OLAP gồm **roll-up**, **drill-down**, **slice**, **dice** và **pivot**; OLAP server có 3 loại: **ROLAP** (lưu trên CSDL quan hệ), **MOLAP** (mảng đa chiều) và **HOLAP** (kết hợp).

Hệ thống dùng **ROLAP**: dữ liệu chi tiết nằm trong bảng quan hệ của PostgreSQL, mỗi thao tác OLAP được dịch thành 1 câu `SELECT … GROUP BY` nối fact với các dimension. Các phép tổng hợp hay dùng được **tính sẵn** bằng materialized view:

Materialized view	Nội dung	Dùng ở
`mv_monthly_kpi`	Theo tháng: doanh thu, phí ship, số sản phẩm, số đơn, số đơn giao, tỷ lệ trễ, số ngày giao TB, review TB, tỷ lệ review xấu (kết hợp 2 fact)	Home
`mv_sales_cube`	`GROUP BY CUBE (year, customer_region, category)` : mọi tổ hợp cùng các dòng tổng phụ (NULL = "Tất cả")	OLAP
`mv_delivery_by_state`	Theo bang: số đơn, tỷ lệ trễ, ngày giao TB, review TB, tỷ lệ review xấu, doanh thu	Delivery

3.6 Frontend: dashboard Streamlit

Dashboard gồm 5 trang:

Trang	Nội dung	Trả lời câu hỏi
Home	KPI tổng và xu hướng theo tháng	Phân tích 1
OLAP	Roll-up, drill-down, slice, dice, pivot trên 2 fact	Phân tích 1, 2
Delivery	Giao hàng và review theo mức trễ, bang, danh mục	Phân tích 2, 3
DSS	5 tab: mô hình, xếp hạng, what-if & sensitivity, goal seeking, tối ưu ngân sách	Quyết định 1–5
Data Quality	Kết quả kiểm tra, số dòng qua từng bước, lịch sử chạy, quy tắc làm sạch, mô hình train từ lần ETL nào	Độ tin cậy dữ liệu

3.6.1 Trang OLAP

Bảng 3.5: Định nghĩa khối dữ liệu trong ứng dụng

Thành phần	Lựa chọn
Fact	`fact_sales` hoặc `fact_delivery` (2 fact dùng chung dimension, minh hoạ fact constellation)
Measures – fact_sales	Doanh thu (SUM price); Phí vận chuyển (SUM); Số sản phẩm (COUNT); Số đơn (COUNT DISTINCT); Giá TB / sản phẩm (AVG)
Measures – fact_delivery	Số đơn đã giao (COUNT); Tỷ lệ giao trễ (%); Số ngày giao TB; Điểm review TB; Tỷ lệ review xấu (%)
Hierarchy Thời gian	Năm → Quý → Tháng
Hierarchy Địa lý khách hàng / người bán	Vùng → Bang → Thành phố
Hierarchy Sản phẩm	Danh mục

Bảng 3.6: Hiện thực 5 phép toán OLAP

Phép toán	Thao tác trên giao diện	SQL tương ứng
Roll-up	Nút "Roll-up" (vd. Tháng → Quý → Năm)	`GROUP BY` theo cột cấp cao hơn
Drill-down	Nút "Drill-down" (vd. Năm → Quý → Tháng)	`GROUP BY` theo cột cấp thấp hơn
Slice	Chọn "Cố định năm" = 2017	`WHERE d.year = :year`
Dice	Chọn nhiều bang và nhiều danh mục	`WHERE c.state = ANY(:states) AND p.category_en = ANY(:categories)`
Pivot	Nút "Pivot" đổi chiều hàng ↔ cột	Đổi vai trò 2 cột trong `GROUP BY 1, 2` + `pivot_table`

Một số chi tiết khác của trang:

- **Hiển thị:** bảng pivot kèm heatmap (khi có chiều cột), hoặc biểu đồ cột (khi chỉ có chiều hàng).
- **SQL sinh ra:** hiện trong mục "SQL được sinh ra".
- **Additive vs non-additive:** chỉ measure additive mới có dòng / cột "Tổng". Với measure non-additive, trang hiện ghi chú vì sao không cộng dồn được.
- **An toàn SQL:** chỉ các biểu thức có sẵn trong cấu hình (whitelist) mới được đưa vào SQL; giá trị người dùng chọn được truyền qua tham số.

[HÌNH] Mỗi phép toán một ảnh: roll-up, drill-down, slice, dice, pivot. Thêm 1 ảnh mục "SQL được sinh ra" và 1 ảnh khi chọn fact_delivery

Ví dụ kết quả các phép toán

Doanh thu ở đây là tổng giá sản phẩm, loại đơn canceled / unavailable.

Bảng 3.7: Roll-up về cấp cao nhất (dòng "Tất cả" do `CUBE` sinh ra)

Năm	Doanh thu (R$)	Số sản phẩm	Số đơn	Giá trị TB / đơn (R$)
2016	44.726,06	348	293	152,65
2017	6.108.492,27	50.617	44.375	137,66
2018	7.341.182,41	61.136	53.531	137,14
Tất cả	**13.494.400,74**	**112.101**	**98.199**	**137,42**

(Gợi ý biểu đồ: cột)

Bảng 3.8: Drill-down Năm → Quý

Quý	Doanh thu (R$)	Số đơn
2016-Q3	207,86	2
2016-Q4	44.518,20	291
2017-Q1	733.398,94	5.122
2017-Q2	1.286.918,78	9.222
2017-Q3	1.681.949,00	12.445
2017-Q4	2.406.225,55	17.586
2018-Q1	2.764.402,78	20.979
2018-Q2	2.849.730,26	19.897
2018-Q3	1.727.049,37	12.655

Bảng 3.9: Drill-down 2018-Q1 → Tháng

Tháng	Doanh thu (R$)
2018-01	945.456,29
2018-02	837.895,43
2018-03	981.051,06

Bảng 3.10: Slice năm 2017, theo vùng khách hàng

Vùng	Doanh thu 2017 (R$)
Southeast	3.930.293,30
South	881.752,70
Northeast	727.528,43
Central-West	400.781,10
North	168.136,74

Ghi chú: dữ liệu 2018-Q3 chỉ đến hết tháng 8, và tháng 9/2018 chỉ có 1 đơn.

Bảng 3.11: Pivot vùng × năm (doanh thu, R$). Đổi trục sẽ cho bảng năm × vùng

Vùng \ Năm	2016	2017	2018	Tổng
Southeast	27.700,71	3.930.293,30	4.866.163,13	8.824.157,14
South	7.455,89	881.752,70	1.047.635,66	1.936.844,25
Northeast	6.013,32	727.528,43	804.697,84	1.538.239,59
Central-West	2.355,95	400.781,10	458.089,53	861.226,58
North	1.200,19	168.136,74	164.596,25	333.933,18
Tổng	44.726,06	6.108.492,27	7.341.182,41	13.494.400,74

(Gợi ý biểu đồ: heatmap / cột chồng)

Bảng 3.12: Dice: bang ∈ {SP, RJ}, danh mục ∈ {health_beauty, bed_bath_table} (doanh thu, R$)

Năm	Bang	bed_bath_table	health_beauty
2016	RJ	59,90	1.237,79
2016	SP	29,90	1.079,04
2017	RJ	80.141,28	64.378,98
2017	SP	207.777,67	157.016,53
2018	RJ	67.562,26	79.176,36
2018	SP	270.371,52	302.498,32

Bảng 3.13: Top 10 bang theo doanh thu

Bang	Doanh thu (R$)	Số đơn
SP	5.165.781,70	41.130
RJ	1.811.484,23	12.698
MG	1.573.269,18	11.493
RS	742.639,78	5.415
PR	675.928,19	4.980
SC	518.276,28	3.600
BA	506.878,84	3.342
DF	300.085,75	2.117
GO	288.157,45	1.997
ES	273.622,03	2.019

Bảng 3.14: Top 10 danh mục theo doanh thu

Danh mục	Doanh thu (R$)	Số SP	Số đơn
health_beauty	1.255.695,13	9.634	8.800
watches_gifts	1.198.185,21	5.970	5.604
bed_bath_table	1.035.964,06	11.097	9.399
sports_leisure	979.740,92	8.590	7.673
computers_accessories	904.322,02	7.781	6.654
furniture_decor	727.465,05	8.298	6.425
housewares	626.825,80	6.915	5.847
cool_stuff	620.770,49	3.779	3.616
auto	586.585,73	4.204	3.872
garden_tools	481.009,94	4.328	3.505

3.6.2 Trang Home

Bảng 3.15: KPI tổng

KPI	Giá trị
Doanh thu (giá sản phẩm, loại canceled / unavailable)	R$ 13.494.400,74
Phí vận chuyển	R$ 2.241.126,29
Số đơn hàng	98.199
Số sản phẩm bán	112.101
Giá trị TB / đơn	R$ 137,42
Khách hàng có mua / người bán có bán / sản phẩm đã bán	95.420 / 3.095 / 32.951
Số đơn đã giao	96.470
Tỷ lệ giao trễ	6,77%
Số ngày giao TB / số ngày dự kiến TB	12,50 / 24,37 ngày
Điểm review TB	4,156
Tỷ lệ review xấu ($\leq$ 2 sao)	12,81%
Đơn đã giao không có review	646

[HÌNH] Trang Home

Xu hướng theo tháng. Dashboard chỉ vẽ giai đoạn 2017-01 $\rightarrow$ 2018-08, vì các tháng ở hai đầu có rất ít đơn (2016-09: 2 đơn, 2016-12: 1 đơn, 2018-09: 1 đơn; tháng 2016-11 không có đơn).

Bảng 3.16: Xu hướng theo tháng

Tháng	Doanh thu (R$)	Số đơn	Đơn đã giao	Tỷ lệ trễ	Ngày giao TB	Review TB	Review xấu
2016-10	44.507,30	290	265	0,75%	19,63	4,011	16,41%
2017-01	120.098,27	787	750	2,93%	12,75	4,198	12,01%
2017-02	244.959,35	1.718	1.653	2,96%	13,30	4,203	11,08%
2017-03	368.341,32	2.617	2.546	4,56%	13,04	4,187	11,24%
2017-04	353.842,98	2.377	2.303	6,56%	15,02	4,135	12,93%
2017-05	503.159,19	3.640	3.545	2,99%	11,43	4,236	10,07%
2017-06	429.916,61	3.205	3.135	3,03%	12,01	4,223	10,74%
2017-07	492.287,30	3.946	3.872	2,79%	11,49	4,260	9,94%
2017-08	568.245,79	4.272	4.193	2,91%	11,02	4,313	9,39%
2017-09	621.415,91	4.227	4.150	4,39%	11,72	4,268	10,27%
2017-10	660.179,62	4.547	4.478	4,18%	11,73	4,205	11,07%

Tháng	Doanh thu (R$)	Số đơn	Đơn đã giao	Tỷ lệ trễ	Ngày giao TB	Review TB	Review xấu
2017-11	1.003.862,14	7.421	7.288	12,40%	15,07	3,989	16,57%
2017-12	742.183,79	5.618	5.513	7,46%	15,31	4,088	14,43%
2018-01	945.456,29	7.187	7.069	5,70%	14,01	4,109	13,70%
2018-02	837.895,43	6.624	6.555	14,13%	16,87	3,881	19,38%
2018-03	981.051,06	7.168	7.003	18,96%	16,24	3,813	21,17%
2018-04	993.592,98	6.919	6.798	4,50%	11,42	4,206	11,79%
2018-05	992.871,75	6.833	6.749	6,56%	11,34	4,236	10,76%
2018-06	863.265,53	6.145	6.096	1,16%	9,16	4,307	9,98%
2018-07	878.044,27	6.233	6.156	3,38%	8,89	4,317	9,68%
2018-08	848.860,10	6.421	6.351	6,19%	7,66	4,310	9,54%

(Gợi ý biểu đồ: cột doanh thu + đường tỷ lệ trễ và tỷ lệ review xấu)

Insight:

- Tỷ lệ trễ và tỷ lệ review xấu **tăng giảm cùng nhau**. Hai đỉnh là 11/2017 (trễ 12,4% $\rightarrow$ review xấu 16,6%; tháng có Black Friday, số đơn tăng vọt lên 7.421) và 02–03/2018 (trễ 14,1–19,0% $\rightarrow$ review xấu 19,4–21,2%).
- Các tháng trễ thấp (06/2018: 1,16%) có tỷ lệ review xấu thấp nhất ($\sim$10%).

3.6.3 Trang Delivery

Bảng 3.17: Review theo mức độ trễ (discretization)

Giao so với ngày dự kiến	Số đơn	Review TB	Tỷ lệ review xấu
Sớm $>$ 7 ngày	71.303	4,317	8,97%
Sớm 1–7 ngày	17.341	4,201	10,24%
Đúng ngày	1.292	4,034	12,42%
Trễ 1–3 ngày	1.870	3,291	32,13%
Trễ 4–7 ngày	1.802	2,103	67,68%
Trễ 8–14 ngày	1.478	1,671	80,15%
Trễ $>$ 14 ngày	1.384	1,724	78,35%

(Gợi ý biểu đồ: cột — đây là biểu đồ "đắt" nhất để thuyết trình)

Bảng 3.18: Phân bố điểm review: đúng hạn và trễ (đơn có review)

Điểm	Đúng hạn	Trễ
1 sao	5.920	3.431
2 sao	2.369	552
3 sao	7.222	694
4 sao	18.239	649
5 sao	55.693	1.055
Tổng	89.443	6.381

(Gợi ý biểu đồ: cột chồng 100%)

Với đơn trễ, **53,8%** là 1 sao (3.431 / 6.381). Với đơn đúng hạn, **62,3%** là 5 sao (55.693 / 89.443).

Bảng 3.19: Giao hàng theo vùng khách hàng

Vùng	Số đơn	Tỷ lệ trễ	Ngày giao TB	Review TB	Tỷ lệ review xấu
Northeast	9.045	12,71%	19,94	3,970	16,74%
North	1.797	8,57%	22,54	4,031	15,17%
Central-West	5.619	6,50%	14,95	4,129	13,12%
Southeast	66.197	6,12%	10,69	4,179	12,38%
South	13.812	5,90%	13,98	4,191	11,82%

Bảng 3.20: Giao hàng theo bang (sắp theo tỷ lệ trễ giảm dần)

Bang	Vùng	Số đơn	Tỷ lệ trễ	Ngày giao TB	Review TB	Review xấu
AL	Northeast	397	21,41%	24,50	3,848	21,32%
MA	Northeast	720	17,36%	21,48	3,835	19,86%
SE	Northeast	336	15,18%	21,42	3,907	18,86%
PI	Northeast	476	13,87%	19,39	3,994	16,14%
CE	Northeast	1.281	13,74%	21,18	3,946	17,10%
RR	North	41	12,20%	29,34	3,902	14,63%
BA	Northeast	3.254	12,17%	19,28	3,931	17,01%
RJ	Southeast	12.351	12,11%	15,24	3,965	18,33%
PA	North	946	11,21%	23,73	3,914	17,90%
ES	Southeast	1.996	10,72%	15,73	4,079	13,81%
PB	Northeast	515	10,29%	20,37	4,082	14,71%

Bang	Vùng	Số đơn	Tỷ lệ trễ	Ngày giao TB	Review TB	Review xấu
TO	North	274	9,85%	17,60	4,154	12,09%
MS	Central-West	700	9,71%	15,54	4,160	13,32%
PE	Northeast	1.592	9,67%	18,38	4,080	14,89%
RN	Northeast	474	9,28%	19,22	4,151	12,95%
SC	South	3.547	8,20%	14,90	4,135	12,95%
GO	Central-West	1.956	6,49%	15,53	4,106	13,16%
MT	Central-West	886	6,09%	18,01	4,147	12,74%
RS	South	5.344	6,08%	15,25	4,185	11,92%
DF	Central-West	2.077	5,58%	12,89	4,134	13,16%
MG	Southeast	11.351	4,58%	11,95	4,192	11,76%
SP	Southeast	40.499	4,49%	8,70	4,246	10,69%
PR	South	4.921	4,04%	11,94	4,239	10,90%
AC	North	80	3,75%	21,00	4,088	15,00%
AP	North	67	2,99%	27,18	4,242	6,06%
RO	North	244	2,87%	19,28	4,165	11,93%
AM	North	145	2,76%	26,36	4,243	13,19%

(Gợi ý biểu đồ: cột tỷ lệ trễ theo bang, tô màu theo tỷ lệ review xấu)

Insight:

- Vùng Northeast trễ nhiều nhất (12,7%).
- **RJ** đáng chú ý: là bang lớn thứ 2 (12.351 đơn) nhưng trễ 12,1% và có tỷ lệ review xấu cao nhất trong nhóm bang lớn (18,3%).
- SP giao nhanh nhất (8,7 ngày) và ít trễ (4,5%).

Bảng 3.21: Giao hàng theo danh mục ($\geq$ 500 đơn, sắp theo tỷ lệ review xấu)

Danh mục	Số đơn	Tỷ lệ trễ	Review TB	Review xấu
office_furniture	1.251	8,07%	3,647	21,92%
unknown	1.358	7,14%	4,041	16,53%
bed_bath_table	9.184	7,48%	4,008	15,82%
furniture_decor	6.188	7,24%	4,078	14,85%
computers_accessories	6.511	6,40%	4,083	14,51%
telephony	4.073	7,14%	4,059	13,93%
baby	2.761	8,11%	4,122	13,76%
watches_gifts	5.476	7,41%	4,123	13,65%

Danh mục	Số đơn	Tỷ lệ trễ	Review TB	Review xấu
electronics	2.502	7,67%	4,129	13,05%
auto	3.792	7,33%	4,153	12,80%
construction_tools_construction	724	7,46%	4,152	12,66%
garden_tools	3.400	6,62%	4,200	11,74%
perfumery	3.069	6,58%	4,268	11,57%
housewares	5.680	5,42%	4,204	11,57%
musical_instruments	608	7,57%	4,243	11,46%
health_beauty	8.613	7,54%	4,233	11,35%
small_appliances	606	4,79%	4,266	11,31%
toys	3.787	6,42%	4,240	11,31%
sports_leisure	7.492	6,59%	4,235	11,20%
consoles_games	1.013	6,12%	4,182	11,06%
home_appliances	747	4,42%	4,212	11,02%
cool_stuff	3.530	5,92%	4,230	10,91%
pet_shop	1.682	5,05%	4,275	10,57%
fashion_bags_accessories	1.811	5,58%	4,243	10,09%
stationery	2.244	6,60%	4,307	9,68%
luggage_accessories	1.012	4,25%	4,371	8,13%

Insight: khác biệt giữa các danh mục về tỷ lệ trễ nhỏ hơn nhiều so với khác biệt giữa các bang (4,2–8,1% so với 2,8–21,4%). Tuy vậy, office_furniture có tỷ lệ review xấu rất cao (21,9%) dù tỷ lệ trễ chỉ trung bình. Điều này cho thấy còn nguyên nhân khác ngoài giao hàng (hàng cồng kềnh, lắp ráp…).

Phân tích bổ sung (dữ liệu đầu vào cho DSS)

Bảng 3.22: Ảnh hưởng của số sản phẩm và số người bán trong đơn (đơn có review)

Số SP trong đơn	Người bán	Trễ?	Số đơn	Tỷ lệ review xấu
1	1	Không	80.407	7,55%
1	1	Có	5.889	62,10%
2	1	Không	6.000	19,72%
2	1	Có	373	65,42%
2	Nhiều	Không	935	45,35%
2	Nhiều	Có	11	72,73%
≥3	1	Không	1.787	25,35%
≥3	1	Có	107	68,22%
≥3	Nhiều	Không	314	51,59%
≥3	Nhiều	Có	1	100,00%

Insight: đơn có **nhiều người bán** có tỷ lệ review xấu 45–52% **ngay cả khi giao đúng hạn**. Nguyên nhân có thể là hàng về thành nhiều lần, hoặc khách đánh giá ngay khi mới nhận được một phần đơn.

Bảng 3.23: Người bán và khách cùng bang hay khác bang

Cùng bang?	Số đơn	Ngày giao TB	Tỷ lệ trễ	Tỷ lệ review xấu
Khác bang	61.776	15,09	8,05%	14,12%
Cùng bang	34.694	7,89	4,51%	10,47%

[HÌNH] Trang Delivery

3.6.4 Trang Data Quality

Trang hiển thị:

- kết quả kiểm tra theo nhóm;
- số dòng qua từng bước CSV → staging → dw;
- lịch sử các lần chạy;
- các quy tắc làm sạch đang áp dụng;
- mô hình DSS đang dùng được train từ lần ETL nào.

[HÌNH] Trang Data Quality

Chương 4. Hệ thống hỗ trợ ra quyết định

4.1 Cơ sở lý thuyết

- DSS là *"a computer-based system that supports decision-making activities by integrating data, sophisticated analytical models, and user-friendly software tools"* (slide Ch.6).
- Các subsystem: **data management, model management, user interface (dialog)**, và knowledge-based (tuỳ chọn).
- Quá trình ra quyết định của Simon gồm các pha **intelligence, design, choice, implementation** (và **evaluation**) (slide Ch.5).
- Mô hình gồm **decision variables, uncontrollable variables, result variables**, và được xây trong điều kiện **certainty / risk / uncertainty** (slide Ch.7).

4.2 Phân loại, kiến trúc và quá trình ra quyết định

Phân loại (slide Ch.4): Hybrid DSS, gồm hai phần:

- **data-driven:** truy vấn và OLAP trên kho dữ liệu;
- **model-driven:** cây quyết định cùng các phân tích what-if, sensitivity, goal seeking, và mô hình tối ưu (mathematical programming) để phân bổ ngân sách.

Theo phân loại của Holsapple & Whinston (slide Ch.6), đây là dạng *compound DSS*, kết hợp database-oriented và solver-oriented.

Bảng 4.1: Kiến trúc subsystem (theo ví dụ "business analytics DSS" trong slide Ch.6)

Subsystem	Hiện thực trong project
Data management	Kho dữ liệu PostgreSQL (schema `dw`): `fact_delivery` cùng các dimension, nạp bằng ETL (Chương 2)
Model management	`src/dss/train_model.py` (cây quyết định, model base lưu ở `models/`); `src/dss/whatif.py` (what-if, sensitivity, goal seeking, xếp hạng); `src/dss/optimizer.py` (tối ưu ngân sách, phân tích độ vững); `config/cost_assumptions.csv` (giả định chi phí)
User interface (dialog)	Trang DSS trên Streamlit, gồm 5 tab: chọn phạm vi, kéo thanh trượt, nhập mục tiêu, nhập ngân sách và giả định, xem bảng và biểu đồ
Knowledge-based (tuỳ chọn)	Tập luật IF-THEN rút ra từ cây quyết định, dùng để giải thích cho người quản lý

Vai trò của DW trong DSS (L.O.1.2): DW là *data management subsystem*. Nó cung cấp dữ liệu đã tích hợp và làm sạch, đúng grain (đơn hàng), cho cả phần OLAP (data-driven) lẫn mô hình (model-driven). Nếu không có bước chuẩn hoá ở DW, mô hình sẽ bị sai vì review trùng, đơn nhiều item, hoặc thiếu ngày giao.

Bảng 4.2: Ánh xạ quá trình ra quyết định của Simon

Pha	Câu hỏi	Công cụ trong hệ thống	Kết quả
Intelligence	Có vấn đề gì? Ở đâu?	Home, OLAP, Delivery	Giao trễ → review xấu; Northeast và RJ trễ nhiều; đỉnh 11/2017 và 02–03/2018
Design	Mô hình hoá vấn đề, liệt kê phương án	DSS tab 1: cây quyết định và luật	Các nhóm đơn rủi ro cao; biến quyết định = mức giảm trễ, số ngày rút ngắn
Choice	Chọn phương án	DSS tab 2–5: xếp hạng, what-if, sensitivity, goal seeking, tối ưu ngân sách	Ưu tiên RJ, GO, PR, RN ở mọi bộ giả định chi phí; cần giảm 58% đơn trễ để đạt 11%
Implementation	Hành động gì?	Khung "Đề xuất" tự sinh ở tab 2 và tab 5	Phân bổ ngân sách theo bang, đổi / thêm đơn vị vận chuyển, nới ngày giao dự kiến
Evaluation	Mô hình tin được đến đâu?	Metrics, confusion matrix, thực nghiệm chọn tham số, kiểm tra trên tập test; độ nhạy theo giả định chi phí	Mục 4.3.4, 4.4, 4.5.5 và Chương 5

[HÌNH] 5 tab của trang DSS

4.3 Mô hình cây quyết định

4.3.1 Dữ liệu và thuộc tính

- **Tập dữ liệu:** các đơn trong `fact_delivery` **có review**, tổng **95.824 đơn** (đã loại 646 đơn không có review). Tỷ lệ review xấu là 12,81%. Trong tập này, tỷ lệ trễ là 6,66% (6.381 đơn).
- **Biến mục tiêu:** `is_bad_review` (1 nếu điểm ≤ 2).
- **Chia dữ liệu:** train 76.659 / test 19.165 (80/20, stratified, `random_state = 42`).

Bảng 4.3: Các thuộc tính đầu vào

Thuộc tính	Nguồn	Ý nghĩa
is_late	fact_delivery	Có trễ không
delay_days	fact_delivery	Số ngày trễ (âm = sớm)
delivery_days	fact_delivery	Số ngày giao thực tế
estimated_days	fact_delivery	Số ngày giao dự kiến
n_items	fact_delivery	Số sản phẩm trong đơn
n_sellers	fact_delivery	Số người bán trong đơn
freight_ratio	freight_total / order_value	Tỷ lệ phí ship so với giá trị đơn
same_state	dim_customer.state = dim_seller.state	Người bán và khách cùng bang
region_* (5 cột)	dim_customer.region (one-hot)	Vùng của khách

4.3.2 Thuật toán, cấu hình và chọn tham số

Thuật toán là cây quyết định với tiêu chí **entropy / information gain**, thuộc họ ID3 / C4.5. Đây là thuật toán có ví dụ tính tay trong slide Ch.5 (bộ dữ liệu *buys_computer*).

Bảng 4.4: Cấu hình cây quyết định

Tham số	Giá trị	Lý do
criterion	entropy	Dùng information gain như trong lecture
max_depth	4	Cây nhỏ, dễ giải thích (chọn bằng thực nghiệm bên dưới)
min_samples_leaf	200	Mỗi lá đủ lớn để tỷ lệ trong lá có ý nghĩa thống kê
class_weight	balanced	Review xấu là lớp thiểu số (12,8%)
random_state	42	Tái lập kết quả

Cây thu được có **độ sâu 4 và 15 lá**.

Thực nghiệm chọn tham số. Nhóm so sánh 12 cấu hình `max_depth` $\in \{3, 4, 5, 6\} \times$ `min_samples_leaf` $\in \{100, 200, 500\}$ bằng **cross-validation 5-fold (stratified) trên tập train**. Tập test không được dùng ở bước này, để nó vẫn là phép kiểm tra cuối cùng khách quan. Cây được dùng theo hai cách, nên nhóm đo hai loại chỉ số:

- chỉ số **phân loại** (accuracy, precision, recall, F1 của lớp review xấu);
- chỉ số **chất lượng xác suất**, vì what-if dùng tỷ lệ của lá làm xác suất: AUC (càng cao càng tốt) và Brier score (càng thấp càng tốt).

Bảng 4.5: Thực nghiệm chọn tham số, đủ 12 cấu hình (trung bình 5 fold; nguồn: `models/experiments.json`)

depth	leaf	Số lá	Accuracy	Precision	Recall	F1	AUC	Brier
3	100	8	83,76%	39,99%	50,73%	0,4452	0,7307	0,0876
3	200	8	83,76%	39,99%	50,73%	0,4452	0,7307	0,0877
3	500	8	83,76%	39,99%	50,73%	0,4452	0,7307	0,0878
4	100	15	80,69%	34,43%	56,04%	0,4264	0,7408	0,0874
4	**200**	**15**	**80,69%**	**34,43%**	**56,04%**	**0,4264**	**0,7408**	**0,0874**
4	500	14	80,69%	34,43%	56,04%	0,4264	0,7407	0,0876
5	100	26	81,27%	35,46%	54,87%	0,4295	0,7436	0,0872
5	200	24	81,21%	35,38%	55,06%	0,4294	0,7436	0,0872
5	500	21	81,15%	35,29%	55,05%	0,4287	0,7435	0,0874
6	100	44	82,16%	36,82%	54,07%	0,4376	0,7455	0,0871
6	200	39	82,19%	36,85%	54,02%	0,4377	0,7456	0,0872
6	500	31	82,20%	36,80%	53,78%	0,4366	0,7456	0,0873

Lý do giữ depth 4 / leaf 200:

- Depth 3 có F1 cao nhất nhưng AUC thấp nhất. Cây chỉ có 8 lá thì phân nhóm rủi ro quá thô cho what-if.
- Depth 5–6 chỉ tăng AUC thêm khoảng 0,003–0,005 nhưng số lá tăng gấp 2–3 lần, nên khó giải thích bằng luật IF-THEN hơn.
- Với depth 4, `min_samples_leaf` gần như không đổi kết quả. Chọn 200 để mỗi lá đủ lớn.

4.3.3 Ví dụ tính information gain (theo công thức slide Ch.5)

Bảng 4.6: Bảng đếm (95.824 đơn có review)

is_late	Số đơn	Review xấu	Review tốt
0	89.443	8.289	81.154
1	6.381	3.983	2.398
Tổng (D)	**95.824**	**12.272**	**83.552**

$$\begin{aligned}
\text{Info}(D) &= -\tfrac{12272}{95824}\log_2\tfrac{12272}{95824} - \tfrac{83552}{95824}\log_2\tfrac{83552}{95824} = 0{,}5521 \\
\text{Info}(D \mid \text{is_late}=0) &= -\tfrac{8289}{89443}\log_2\tfrac{8289}{89443} - \tfrac{81154}{89443}\log_2\tfrac{81154}{89443} = 0{,}4453 \\
\text{Info}(D \mid \text{is_late}=1) &= -\tfrac{3983}{6381}\log_2\tfrac{3983}{6381} - \tfrac{2398}{6381}\log_2\tfrac{2398}{6381} = 0{,}9550 \\
\text{Info}_{\text{is_late}}(D) &= \tfrac{89443}{95824}\cdot 0{,}4453 + \tfrac{6381}{95824}\cdot 0{,}9550 = 0{,}4793 \\
\text{Gain}(\text{is_late}) &= 0{,}5521 - 0{,}4793 = \mathbf{0{,}0728}\ \text{bit}
\end{aligned}$$

Bảng 4.7: So sánh với các thuộc tính khác (tính cùng công thức)

Thuộc tính	Gain (bit)
is_late	0,0728
n_sellers >1	0,0068
region (5 vùng)	0,0011

Nhận xét:

- Giao trễ mang thông tin gấp khoảng **10 lần** số người bán và gấp khoảng **66 lần** vùng địa lý.
- Trên cây thực tế, thuộc tính được chọn ở gốc là `delay_days` (dạng liên tục, ngưỡng 1,5 ngày), không phải `is_late`. Lý do: ngưỡng tối ưu tách tốt hơn ngưỡng 0, vì đơn chỉ trễ 1 ngày chưa bị phạt nặng. Vì vậy độ quan trọng của `is_late` trên cây bằng 0.

4.3.4 Kết quả đánh giá trên tập test (19.165 đơn)

Bảng 4.8: Chỉ số

Chỉ số	Giá trị
Accuracy	79,67%
Precision (lớp xấu)	32,95%
Recall (lớp xấu)	56,76%
F1 (lớp xấu)	0,417

Bảng 4.9: Confusion matrix

	Dự đoán: tốt	Dự đoán: xấu
Thực tế: tốt	13.876 (TN)	2.835 (FP)
Thực tế: xấu	1.061 (FN)	1.393 (TP)

Bảng 4.10: Độ quan trọng của thuộc tính

Thuộc tính	Importance
delay_days	0,7160
n_items	0,1936
delivery_days	0,0689
n_sellers	0,0215
is_late, estimated_days, freight_ratio, same_state, region_*	0

(Gợi ý biểu đồ: cột ngang)

Diễn giải:

- Mô hình bắt được khoảng 57% đơn bị review xấu chỉ từ dữ liệu giao hàng.
- Precision thấp là điều có thể dự đoán trước. Review xấu còn do nhiều nguyên nhân không có trong dữ liệu (chất lượng sản phẩm, sai mô tả…).
- Mục đích chính của cây trong DSS là **phân nhóm rủi ro và giải thích**, không phải dự đoán từng đơn.

4.3.5 Luật IF-THEN (15 lá, sắp theo rủi ro)

P = tỷ lệ review xấu thực tế của nhóm trên tập train; n = số đơn train trong nhóm.

Bảng 4.11: 15 luật IF-THEN rút ra từ cây

#	IF	P(review xấu)	n
1	5,5 $<$ delay_days $\leq$ 34,5	79,73%	2.684
2	4,5 $<$ delay_days $\leq$ 5,5	64,23%	355
3	delay_days $>$ 34,5	61,76%	204
4	2,5 $<$ delay_days $\leq$ 4,5 AND delivery_days $>$ 22,5	57,46%	496
5	delay_days $\leq$ 1,5 AND n_items $>$ 1,5 AND n_sellers $>$ 1,5 AND delivery_days $>$ 11,5	54,10%	244
6	2,5 $<$ delay_days $\leq$ 4,5 AND delivery_days $\leq$ 22,5	48,57%	245
7	delay_days $\leq$ 1,5 AND n_items $>$ 1,5 AND n_sellers $>$ 1,5 AND delivery_days $\leq$ 11,5	45,55%	764
8	1,5 $<$ delay_days $\leq$ 2,5 AND freight_ratio $\leq$ 0,23	35,87%	223
9	1,5 $<$ delay_days $\leq$ 2,5 AND freight_ratio $>$ 0,23	33,66%	202
10	delay_days $\leq$ 1,5 AND n_items $>$ 1,5 AND n_sellers $\leq$ 1,5 AND delivery_days $>$ 7,5	24,22%	4.113

#	IF	P(review xấu)	n
11	delay_days $\leq$ 1,5 AND n_items $\leq$ 1,5 AND delivery_days $>$ 21,5	15,23%	4.734
12	delay_days $\leq$ 1,5 AND n_items $>$ 1,5 AND n_sellers $\leq$ 1,5 AND delivery_days $\leq$ 7,5	14,78%	2.138
13	delay_days $\leq$ 1,5 AND n_items $\leq$ 1,5 AND 16,5 $<$ delivery_days $\leq$ 21,5	9,64%	6.993
14	delay_days $\leq$ 1,5 AND n_items $\leq$ 1,5 AND 9,5 $<$ delivery_days $\leq$ 16,5	7,72%	21.784
15	delay_days $\leq$ 1,5 AND n_items $\leq$ 1,5 AND delivery_days $\leq$ 9,5	6,05%	31.480

Tri thức rút ra (knowledge):

1. Trễ từ khoảng 5 ngày trở lên $\rightarrow$ khoảng 62–80% bị review xấu (luật 1–3).
2. Trễ 2–4 ngày $\rightarrow$ 34–57%. Rủi ro tăng nếu tổng thời gian giao dài (luật 4, 6, 8, 9).
3. Đơn **nhiều sản phẩm từ nhiều người bán** $\rightarrow$ 46–54% dù không trễ (luật 5, 7).
4. Đơn 1 sản phẩm, đúng hạn, giao $\leq$ 9,5 ngày $\rightarrow$ chỉ khoảng 6% (luật 15). Đây là nhóm lớn nhất, chiếm 31.480 / 76.659 đơn train.
5. Kể cả khi đúng hạn, giao càng lâu thì rủi ro càng tăng: 6,05% ($\leq$ 9,5 ngày) $\rightarrow$ 7,72% (9,5–16,5) $\rightarrow$ 9,64% (16,5–21,5) $\rightarrow$ 15,23% ($>$ 21,5 ngày) (luật 15 $\rightarrow$ 14 $\rightarrow$ 13 $\rightarrow$ 11).

4.4 Mô hình rủi ro và các biến

Mô hình under risk (slide Ch.7). Mỗi đơn được gán một **xác suất** bị review xấu, bằng tỷ lệ review xấu thực tế của lá mà đơn rơi vào (`leaf_rate`). Tỷ lệ review xấu kỳ vọng của một nhóm là trung bình các xác suất đó.

- Không dùng `predict_proba`, vì `class_weight = balanced` làm lệch xác suất.
- Kiểm tra độ khớp: tỷ lệ kỳ vọng do mô hình ước lượng là **12,85%**, tỷ lệ thực tế là **12,81%**.
- **Kiểm tra trên tập test** (19.165 đơn mà mô hình chưa thấy khi train): số review xấu kỳ vọng tính theo `leaf_rate` của tập train là **2.497,6**, số thực tế là **2.454** (lệch 1,8%). So từng lá, tỷ lệ trên tập test lệch trung bình (có trọng số theo số đơn) **0,6 điểm %** so với tập train. Kết luận: xác suất theo lá không bị overfit và dùng được cho what-if. Số liệu nằm ở `leaf_check` trong `models/metrics.json`.

Bảng 4.12: Các loại biến trong mô hình (slide Ch.7)

Loại biến	Trong mô hình
Decision variables	`late_reduction`: % số đơn trễ được làm cho đúng hạn (0–100%); `days_faster`: số ngày rút ngắn cho mọi đơn (0–10); phạm vi áp dụng: toàn quốc / 1 bang / 1 danh mục; (tối ưu) bang và mức giảm được chọn
Uncontrollable variables	Hành vi chấm điểm của khách hàng, phản ánh qua `leaf_rate`; số sản phẩm và số người bán trong đơn
Result variables	Tỷ lệ review xấu kỳ vọng; số review xấu tránh được; tỷ lệ trễ sau can thiệp

Cách mô phỏng (`whatif.simulate`):

- `days_faster = N`: trừ N ngày vào `delivery_days` của mọi đơn trong phạm vi, rồi tính lại `delay_days` và `is_late`.
- `late_reduction = X`: chọn X% số đơn đang trễ trong phạm vi và cho giao **đúng ngày dự kiến**, tức `delivery_days = estimated_days`, `delay_days = 0`, `is_late = 0`. Đơn được chọn dựa trên một số ngẫu nhiên cố định cho mỗi đơn (seed 42). Nhờ vậy kết quả tái lập được, và tập đơn được sửa ở mức X% lớn luôn chứa tập ở mức nhỏ hơn, nên tỷ lệ kỳ vọng giảm **đơn điệu**.
- Sau khi mô phỏng, đưa dữ liệu qua cây để lấy xác suất mới, rồi so sánh với trước khi can thiệp.

4.5 Các công cụ ra quyết định

4.5.1 What-if analysis

Bảng 4.13: Toàn quốc, biến `late_reduction`

Giảm %	Tỷ lệ trễ	Review xấu	Tránh được
0%	6,66%	12,85%	0
10%	6,02%	12,53%	307
25%	5,00%	12,04%	781
50%	3,35%	11,24%	1.549
75%	1,68%	10,44%	2.307
100%	0,00%	9,63%	3.085

Bảng 4.14: Toàn quốc, biến `days_faster`

Rút ngắn	Tỷ lệ trễ	Review xấu	Tránh được
0	6,66%	12,85%	0
1	5,80%	12,26%	564
2	5,24%	11,72%	1.083
3	4,73%	11,23%	1.559
5	3,82%	10,38%	2.369
7	2,90%	9,72%	2.997
10	2,11%	9,06%	3.635

Nhận xét: rút ngắn 3 ngày cho mọi đơn cho hiệu quả tương đương việc sửa 50% đơn trễ (khoảng 1.550 review xấu tránh được). Rút ngắn từ 7 ngày trở lên hiệu quả hơn cả sửa 100% đơn trễ, vì còn giảm rủi ro của các đơn đúng hạn nhưng giao lâu (tri thức 5 ở mục trước).

Bảng 4.15: What-if phạm vi bang RJ (12.212 đơn có review; TQ = toàn quốc)

Kịch bản	Trễ RJ	Review xấu kỳ vọng RJ	Tránh được	Review xấu TQ
Hiện tại	11,93%	16,62% (thực tế 18,33%)	0	12,85%
Giảm 30% đơn trễ	8,25%	14,67%	238	12,60%
Giảm 50% đơn trễ	5,86%	13,38%	395	12,44%
Giảm 100% đơn trễ	0,00%	10,33%	769	12,05%
Rút ngắn 3 ngày	9,52%	14,63%	244	12,60%
Giảm 50% + rút ngắn 3 ngày	4,67%	12,06%	557	12,27%

Ghi chú: ở RJ, mô hình ước lượng thấp hơn thực tế (16,62% so với 18,33%). Nghĩa là RJ còn những yếu tố gây review xấu nằm ngoài các thuộc tính của mô hình.

4.5.2 Sensitivity analysis

Bảng 4.16: Tỷ lệ review xấu kỳ vọng thay đổi theo mức giảm đơn trễ (TQ = toàn quốc)

Giảm % đơn trễ	TQ: tỷ lệ trễ	TQ: review xấu	RJ: tỷ lệ trễ	RJ: review xấu
0%	6,66%	12,85%	11,93%	16,62%
10%	6,02%	12,53%	10,85%	16,03%
20%	5,32%	12,20%	9,51%	15,33%
30%	4,66%	11,87%	8,25%	14,67%
40%	3,99%	11,54%	7,05%	14,04%
50%	3,35%	11,24%	5,86%	13,38%
60%	2,67%	10,91%	4,71%	12,80%
70%	2,01%	10,60%	3,47%	12,16%
80%	1,31%	10,27%	2,19%	11,50%
90%	0,67%	9,95%	1,16%	10,93%
100%	0,00%	9,63%	0,00%	10,33%

(Gợi ý biểu đồ: 2 đường)

Nhận xét:

- Quan hệ gần như **tuyến tính**. Mỗi 10% đơn trễ được sửa làm giảm khoảng 0,32 điểm % review xấu ở toàn quốc, và khoảng 0,63 điểm % ở RJ.
- Đầu tư vào RJ cho hiệu quả trên mỗi đơn **gấp khoảng 2 lần** so với đầu tư dàn trải toàn quốc.
- Ngay cả khi hết hoàn toàn giao trễ, toàn quốc vẫn còn 9,63% review xấu. Đây là phần **không giải quyết được bằng logistics**.

4.5.3 Goal seeking

Hệ thống duyệt `late_reduction` từ 0% đến 100%, mỗi bước 1%. Đây là *complete enumeration* (blind search, slide Ch.7). Kết quả trả về là mức nhỏ nhất đạt mục tiêu.

Bảng 4.17: Goal seeking toàn quốc (hiện tại 12,85%)

Mục tiêu ≤	Cần giảm % đơn trễ	Tỷ lệ trễ sau	Review xấu kỳ vọng	Tránh được
12,5%	11%	5,94%	12,49%	344
12,0%	27%	4,87%	11,98%	840
11,5%	42%	3,85%	11,47%	1.321
11,0%	**58%**	2,80%	10,97%	1.803
10,5%	74%	1,75%	10,48%	2.274
10,0%	89%	0,74%	9,98%	2.751
9,5%	**Không khả thi** (100% đúng hạn vẫn còn 9,63%)			

Bảng 4.18: Goal seeking bang RJ (hiện tại 16,62%)

Mục tiêu ≤	Cần giảm % đơn trễ	Review xấu kỳ vọng
16%	11%	15,94%
15%	26%	14,99%
14%	41%	13,98%
13%	57%	12,98%

Khi mục tiêu không khả thi, hệ thống báo lỗi và gợi ý cần giải pháp khác ngoài logistics: chất lượng sản phẩm, đóng gói, gom đơn nhiều người bán…

[HÌNH] Goal seeking trường hợp không khả thi (mục tiêu 9,5%)

4.5.4 Xếp hạng ưu tiên (Choice)

Với mỗi nhóm, hệ thống giả sử **toàn bộ đơn trễ** trong nhóm được giao đúng hạn, rồi tính số review xấu kỳ vọng tránh được. Chỉ xét các nhóm có ≥ 100 đơn có review.

Bảng 4.19: Top 10 bang

#	Bang	Số đơn	Tỷ lệ trễ	Review xấu	Tránh được	Giá trị trễ (R$)	Giảm trong bang
1	SP	40.271	4,43%	10,69%	805	264.659	2,00 điểm %
2	RJ	12.212	11,93%	18,33%	769	209.710	6,30 điểm %
3	MG	11.282	4,49%	11,76%	227	72.691	2,01 điểm %
4	BA	3.228	11,90%	17,01%	191	60.310	5,92 điểm %
5	RS	5.326	6,03%	11,92%	161	43.109	3,02 điểm %
6	SC	3.520	8,07%	12,95%	130	37.436	3,69 điểm %
7	ES	1.970	10,41%	13,81%	100	27.037	5,10 điểm %
8	CE	1.275	13,65%	17,10%	91	30.226	7,10 điểm %
9	PR	4.898	3,96%	10,90%	86	28.981	1,75 điểm %
10	PE	1.578	9,51%	14,89%	77	26.346	4,89 điểm %

Bảng 4.20: Top 10 danh mục

#	Danh mục	Số đơn	Tỷ lệ trễ	Review xấu	Tránh được	Giá trị trễ (R$)	Giảm trong DM
1	bed_bath_table	9.090	7,33%	15,82%	320	76.649	3,53 điểm %
2	health_beauty	8.567	7,39%	11,35%	315	91.224	3,68 điểm %
3	sports_leisure	7.448	6,53%	11,20%	247	69.474	3,32 điểm %
4	furniture_decor	6.142	7,15%	14,85%	203	56.657	3,31 điểm %
5	watches_gifts	5.436	7,27%	13,65%	195	89.282	3,59 điểm %
6	computers_acc.	6.480	6,28%	14,51%	193	60.655	2,97 điểm %
7	housewares	5.646	5,31%	11,57%	147	37.456	2,61 điểm %
8	telephony	4.049	7,09%	13,93%	132	25.167	3,26 điểm %
9	auto	3.774	7,23%	12,80%	131	64.106	3,47 điểm %
10	toys	3.757	6,18%	11,31%	117	30.243	3,12 điểm %

Hạn chế của xếp hạng này: mọi nhóm đều được giả định sửa *toàn bộ* đơn trễ, và chưa tính chi phí. Vì vậy bảng chỉ cho biết tiềm năng của mỗi nhóm, chưa trả lời được câu hỏi "ngân sách có hạn thì chọn đâu". Câu hỏi đó được giải ở Mục 4.5.5.

4.5.5 Tối ưu phân bổ ngân sách (Choice — mathematical programming)

Câu hỏi quyết định chính: với ngân sách giới hạn, nên giảm đơn trễ ở những bang nào và giảm bao nhiêu, để tránh được nhiều review xấu nhất? Thứ tự ưu tiên có còn đúng khi giả định chi phí thay đổi không?

Mô hình (slide Ch.7: *mathematical programming*, dạng bài toán cái túi nhiều lựa chọn, quy hoạch nguyên 0-1):

$$\max_{x} \sum_{s}\sum_{r} \text{benefit}_{s,r}\, x_{s,r}$$

$$\text{s.t.} \sum_{r} x_{s,r} \le 1 \quad \forall s, \qquad \sum_{s}\sum_{r} \text{cost}_{s,r}\, x_{s,r} \le B,$$

$$\Big(\sum_{s}\sum_{r} x_{s,r} \le K\Big) \text{ (tuỳ chọn)}, \qquad x_{s,r} \in \{0,1\}$$

Thành phần	Trong mô hình
Decision variables	$x_{s,r} = 1$ nếu bang s được giảm r% đơn trễ, với $r \in \{25, 50, 75, 100\}$%
Result variable (hàm mục tiêu)	Tối đa hoá số review xấu tránh được
Ràng buộc	Mỗi bang chọn tối đa 1 mức; tổng chi phí $\le$ ngân sách B; (tuỳ chọn) số bang tối đa K, thể hiện năng lực quản lý
$\text{benefit}_{s,r}$	Tính bằng mô hình what-if (Mục 4.4) cho từng bang và từng mức. Đơn ở các bang khác nhau là tách biệt, nên lợi ích cộng dồn được chính xác
Phạm vi	24 bang có ≥ 100 đơn có review, 4 mức, tổng 96 phương án

Chi phí (BRL) = phí ship thực tế của các đơn trễ được sửa × `surcharge` × `tier[r]`.

- Phí ship lấy **từ DW**, nên chênh lệch chi phí giữa các bang là thật. Ví dụ, phí ship trung bình một đơn ở vùng Southeast là 19,84 BRL, ở vùng North là 41,35 BRL.
- `surcharge` = 0,5 và `tier` = 1 / 1,2 / 1,5 / 2 (càng sửa sâu càng đắt) là **giả định**, vì Olist không công bố chi phí cải thiện giao hàng. Hai tham số này nằm ở `config/cost_assumptions.csv`.
- `surcharge` nhân đều mọi chi phí nên **không làm đổi phương án**, chỉ đổi thang đo của ngân sách. Đã kiểm chứng: surcharge 0,5 với ngân sách 30.000 BRL cho đúng cùng phương án như surcharge 1,0 với 60.000 BRL.

Bảng 4.21: Hai tham số giả định (`config/cost_assumptions.csv`)

Tham số	Giá trị	Ý nghĩa	Ảnh hưởng tới phương án
`surcharge`	0,5	Chi phí can thiệp (đổi hãng vận chuyển, thêm kho trung chuyển, ưu tiên xử lý…) để một đơn trễ giao đúng hạn, ước bằng 50% phí ship của đơn đó	Không đổi phương án, chỉ đổi thước đo ngân sách
`tier_25` … `tier_100`	1,0 / 1,2 / 1,5 / 2,0	Hệ số nhân chi phí mỗi đơn ở mức giảm 25 / 50 / 75 / 100%. Chi phí cận biên tăng dần: những đơn đầu dễ sửa, những đơn cuối khó và đắt	Có ảnh hưởng: quyết định sửa sâu ở ít bang hay sửa nhẹ ở nhiều bang

Kiểm tra giả định trên dữ liệu: trả phí ship cao hơn có làm giao nhanh hơn không? So trong **cùng tuyến** (bang người bán → bang người mua) và **cùng nhóm cân nặng**, trên 78.803 đơn có 1 sản phẩm, chia 4 nhóm theo phí ship:

Bảng 4.22: Phí ship và tốc độ giao trong cùng tuyến, cùng nhóm cân nặng

Nhóm phí ship	Phí ship TB (BRL)	Ngày giao TB	Tỷ lệ trễ
Rẻ nhất 25%	13,43	11,5	6,63%
2	16,13	12,2	7,21%
3	18,97	12,6	6,58%
Đắt nhất 25%	25,87	12,2	6,92%

Kết luận: không. Trong Olist, `freight_value` là phí vận chuyển tiêu chuẩn, không phải lựa chọn giao nhanh. Vì vậy phí ship chỉ được dùng làm **thước đo logistics ở mỗi bang đắt hay rẻ**, không dùng như cơ chế làm đơn nhanh hơn. Can thiệp và mức `surcharge` = 50% là giả định không kiểm chứng được bằng Olist, nhưng `surcharge` không làm đổi phương án.

Thuật toán:

- Giải **chính xác** bằng MILP (SciPy `milp`, solver HiGHS), mỗi lần giải mất khoảng 0,03–0,06 giây.
- Có thêm thuật toán **greedy** (chọn dần bước nâng cấp có lợi ích / chi phí cao nhất) làm baseline, để thấy tối ưu chính xác thêm được bao nhiêu.

Bảng 4.23: Phương án tối ưu với giả định mặc định, theo ngân sách (BRL; TQ = toàn quốc)

Ngân sách	Số bang	Đơn trễ sửa	Tránh được	Review xấu TQ	Greedy	Greedy kém hơn
5.000	2	–	226,1	–	225,6	0,24%
10.000	5	899	448,2	12,85% → 12,38%	446,6	0,36%
20.000	12	1.698	817,5	12,85% → 12,00%	817,5	0,00%
40.000	19	2.893	1.410,9	12,85% → 11,38%	1.405,1	0,41%
80.000	22	–	2.194,7	–	2.194,3	0,02%
160.000	24	–	3.079,8	–	3.078,2	0,05%

(Gợi ý biểu đồ: đường cong ngân sách – lợi ích, có thêm đường greedy)

Nhận xét:

- Lợi ích **giảm dần theo ngân sách** (diminishing returns). 10.000 BRL đầu tiên tránh được 448 review xấu. Tăng ngân sách từ 80.000 lên 160.000 BRL chỉ tránh thêm 885 review.
- Sửa toàn bộ đơn trễ ở cả 24 bang tốn khoảng 160.000 BRL và tránh được khoảng 3.080 review xấu.
- Greedy kém tối ưu tối đa 0,41%. Với dữ liệu này, heuristic đơn giản đã khá tốt. MILP vẫn được dùng vì nó chắc chắn cho kết quả tối ưu và chạy đủ nhanh.

Bảng 4.24: Phương án chi tiết với ngân sách 10.000 BRL (tổng chi phí 9.996 BRL; phí ship và chi phí tính bằng BRL)

Bang	Vùng	Mức giảm	Đơn trễ sửa	Phí ship	Chi phí	Tránh được
SP	Southeast	25%	448	9.308,17	4.654,09	208,7
RJ	Southeast	25%	364	8.450,08	4.225,04	193,8
PR	South	25%	48	1.101,59	550,79	24,7
GO	Central-West	25%	29	736,57	368,29	15,2
RN	Northeast	25%	10	396,17	198,09	5,8

Bảng 4.25: Phương án chi tiết với ngân sách 20.000 BRL (tổng chi phí 19.984 BRL; phí ship và chi phí tính bằng BRL)

Bang	Vùng	Mức giảm	Đơn trễ sửa	Phí ship	Chi phí	Tránh được
SP	Southeast	50%	862	16.510,13	9.906,08	393,9
RJ	Southeast	25%	364	8.450,08	4.225,04	193,8
MG	Southeast	25%	110	2.829,59	1.414,79	48,9
RS	South	25%	90	2.087,27	1.043,63	44,8
SC	South	25%	67	1.534,73	767,37	32,3
ES	Southeast	25%	56	1.344,79	672,40	29,2
PR	South	25%	48	1.101,59	550,79	24,7
DF	Central-West	25%	35	893,92	446,96	16,1
GO	Central-West	25%	29	736,57	368,29	15,2
MT	Central-West	25%	16	538,70	269,35	8,0
AL	Northeast	25%	14	413,43	206,71	7,0
TO	North	25%	7	225,79	112,89	3,5

Bảng 4.26: Phương án chi tiết với ngân sách 40.000 BRL (tổng chi phí 39.966 BRL; phí ship và chi phí tính bằng BRL)

Bang	Vùng	Mức giảm	Đơn trễ sửa	Phí ship	Chi phí	Tránh được
RJ	Southeast	50%	741	17.175,90	10.305,54	395,4
SP	Southeast	50%	862	16.510,13	9.906,08	393,9
MG	Southeast	50%	238	5.838,98	3.503,39	106,2
BA	Northeast	50%	200	5.864,90	3.518,94	100,2
RS	South	50%	161	3.821,27	2.292,76	81,9
SC	South	50%	137	3.009,84	1.805,90	62,4
ES	Southeast	50%	110	2.727,72	1.636,63	56,3
PR	South	50%	91	1.948,85	1.169,31	41,2
GO	Central-West	50%	62	1.479,23	887,54	31,9
DF	Central-West	50%	61	1.459,89	875,93	27,3
CE	Northeast	25%	45	1.720,49	860,25	22,0
PE	Northeast	25%	44	1.447,53	723,77	22,0
PI	Northeast	50%	31	959,32	575,59	15,8
MS	Central-West	50%	35	920,56	552,34	15,5
PA	North	25%	26	1.046,96	523,48	13,7
MT	Central-West	25%	16	538,70	269,35	8,0

Bang	Vùng	Mức giảm	Đơn trễ sửa	Phí ship	Chi phí	Tránh được
AL	Northeast	25%	14	413,43	206,71	7,0
SE	Northeast	25%	12	479,08	239,54	6,6
TO	North	25%	7	225,79	112,89	3,5

Ví dụ khung đề xuất tự sinh ở tab 5 với ngân sách 40.000 BRL:

> Giảm 50% đơn trễ ở RJ, SP, MG, BA, RS, SC, ES, PR, GO, DF, PI, MS; giảm 25% đơn trễ ở CE, PE, PA, MT, AL, SE, TO (tổng chi phí 39.966 BRL, 2.893 đơn trễ được xử lý). Dự kiến tránh được khoảng 1.411 review xấu; tỷ lệ review xấu kỳ vọng toàn quốc giảm từ 12,85% xuống 11,38%.

Bảng 4.27: Độ nhạy theo giả định tier (ngân sách 40.000 BRL; hệ số theo mức 25 / 50 / 75 / 100%)

Kịch bản	Hệ số theo mức	Tránh được	Số bang	Đơn trễ sửa	Phương án
Phẳng	1 / 1 / 1 / 1	1.818,4	8	3.737	ES 50%, GO 50%, PR 50%, RJ 100%, RO 50%, RS 50%, SC 25%, SP 100%
Mặc định	1 / 1,2 / 1,5 / 2	1.410,9	19	2.893	AL 25%, BA 50%, CE 25%, DF 50%, ES 50%, GO 50%, MG 50%, MS 50%, MT 25%, PA 25%, PE 25%, PI 50%, PR 50%, RJ 50%, RS 50%, SC 50%, SE 25%, SP 50%, TO 25%
Dốc	1 / 1,5 / 2,25 / 3,5	1.240,6	20	2.525	AL 25%, BA 25%, CE 25%, DF 25%, ES 25%, GO 50%, MG 25%, MS 50%, MT 25%, PA 25%, PE 25%, PI 25%, PR 25%, RJ 50%, RN 25%, RS 50%, SC 50%, SE 25%, SP 50%, TO 25%

→ `tier` quyết định nên **sửa sâu ở ít bang hay sửa nhẹ ở nhiều bang**. Đây là giả định có ảnh hưởng lớn nhất, nên cần thay bằng báo giá thật của hãng vận chuyển trước khi thực hiện.

Phân tích độ vững (robustness) — câu trả lời chính của DSS

Vì chi phí là giả định, nhóm giải lại bài toán dưới **6 bộ giả định**:

- 2 cách tính chi phí: theo phí ship thật của từng bang; hoặc đồng đều (mọi đơn trễ cùng một giá, bằng phí ship trung bình toàn quốc của một đơn trễ, tức là bỏ hẳn yếu tố phí ship);
- $\times$ 3 kịch bản tier: phẳng / mặc định / dốc;
- mỗi bộ giải ở 3 mức ngân sách (10.000 / 20.000 / 40.000 BRL), tổng 18 lần giải.

Một bang thuộc **ưu tiên k** nếu ở mức ngân sách thứ k nó đã được chọn trong **ít nhất 4/6 bộ giả định**.

Bảng 4.28: Phương án ở ngân sách 10.000 BRL theo từng bộ giả định

Chi phí	Tier	Phương án	Tránh được
Phí ship thật	Phẳng	SP 50%, RS 25%, ES 25%	467,9
Phí ship thật	Mặc định	SP, RJ, PR, GO, RN (đều 25%)	448,2
Phí ship thật	Dốc	SP, RJ, PR, GO, RN (đều 25%)	448,2
Đồng đều	Phẳng	RJ 50%, RN 50%, SE 50%, MS 25%	424,9
Đồng đều	Mặc định	RJ, RS, BA, ES, PR, PE, GO, PA, PI, SE, RN, MS (đều 25%)	413,3
Đồng đều	Dốc	RJ, RS, BA, ES, PR, PE, GO, PA, PI, SE, RN, MS (đều 25%)	413,3

Bảng 4.29: Kết quả phân tích độ vững cho 24 bang (nguồn: `optimizer.robustness()`, tab 5 trang DSS)

#	Bang	Vùng	10k	20k	40k	Số lần chọn /18	Mức giảm khi chọn
Ưu tiên 1 (từ 10.000 BRL)							
1	RJ	Southeast	5/6	5/6	6/6	16	25–100%
2	GO	Central-West	4/6	5/6	6/6	15	25–50%
3	PR	South	4/6	4/6	6/6	14	25–50%
4	RN	Northeast	5/6	4/6	4/6	13	25–50%
Ưu tiên 2 (từ 20.000 BRL)							
5	RS	South	3/6	5/6	6/6	14	25–100%
6	ES	Southeast	3/6	5/6	6/6	14	25–50%
7	SP	Southeast	3/6	5/6	5/6	13	25–100%
8	SE	Northeast	3/6	4/6	5/6	12	25–100%
9	PA	North	2/6	4/6	5/6	11	25–100%
10	SC	South	0/6	4/6	6/6	10	25–50%
11	AL	Northeast	0/6	4/6	5/6	9	25–100%
12	TO	North	0/6	4/6	5/6	9	25–75%
13	MT	Central-West	0/6	4/6	5/6	9	25–75%

#	Bang	Vùng	10k	20k	40k	Số lần chọn /18	Mức giảm khi chọn
14	DF	Central-West	0/6	4/6	4/6	8	25–50%
15	MG	Southeast	0/6	4/6	4/6	8	25–50%
Ưu tiên 3 (từ 40.000 BRL)							
16	BA	Northeast	2/6	3/6	5/6	10	25–100%
17	PI	Northeast	2/6	3/6	5/6	10	25–75%
18	MS	Central-West	3/6	3/6	4/6	10	25–50%
19	PE	Northeast	2/6	3/6	5/6	10	25–100%
20	CE	Northeast	0/6	3/6	5/6	8	25–100%
Ít khi được chọn							
21	RO	North	0/6	2/6	3/6	5	50–75%
22	PB	Northeast	0/6	1/6	3/6	4	25–75%
23	MA	Northeast	0/6	2/6	2/6	4	25–50%
24	AM	North	0/6	1/6	1/6	2	50–75%

Diễn giải:

- **RJ là kết luận vững nhất.** RJ được chọn ở 16/18 lần giải. Điều này khớp với xếp hạng ở Mục 4.5.4: RJ có tỷ lệ trễ cao (11,93%) trên một lượng đơn lớn.
- **SP không thuộc ưu tiên 1, dù đứng đầu về số tuyệt đối.** Ở 10.000 BRL, SP được chọn ở cả 3 bộ giả định tính theo phí ship thật, nhưng không được chọn ở bộ nào tính theo chi phí đồng đều. Như vậy vị trí của SP phụ thuộc vào giả định chi phí, và SP chỉ chắc chắn được chọn từ 20.000 BRL.
- **Mức giảm cụ thể ở mỗi bang phụ thuộc giả định.** Ví dụ, RJ dao động từ 25% đến 100%. Vì vậy hệ thống chỉ báo mức giảm dưới dạng khoảng, còn **thứ tự ưu tiên** mới là kết luận dùng được.

[HÌNH] Tab 5 trang DSS: bảng ưu tiên vững, phương án chi tiết, đường cong ngân sách – lợi ích

4.6 Đề xuất cho nhà quản lý (Implementation)

1. **Ưu tiên RJ, sau đó GO, PR, RN.**
   - Đây là các bang được chọn ngay ở ngân sách nhỏ nhất (10.000 BRL) trong ít nhất 4/6 bộ giả định chi phí.
   - Với RJ, xếp hạng theo tiềm năng cho cùng kết luận. RJ tránh được 769 review xấu, gần bằng SP (805), dù số đơn chỉ bằng khoảng 30% SP. Mức giảm tỷ lệ review xấu trong bang (6,3 điểm %) cao gấp khoảng 3 lần SP.

- SP chỉ nên đưa vào khi ngân sách từ khoảng 20.000 BRL, vì vị trí của SP phụ thuộc giả định chi phí.
- Hành động: đánh giá lại đơn vị vận chuyển tuyến vào RJ, hoặc thêm đơn vị vận chuyển cho tuyến này.
- Trước khi giải ngân: thay `surcharge` và `tier` bằng báo giá thật của hãng vận chuyển, rồi chạy lại tab 5.

2. **Nhóm Northeast (BA, CE, AL, MA, SE…)** có tỷ lệ trễ 12–21%. Nên **nới ngày giao dự kiến** cho sát thời gian thực tế (ngày giao TB 19–25 ngày). Khi ngày dự kiến sát thực tế, một phần đơn sẽ không còn bị tính là trễ.
3. **Đơn nhiều người bán** có 45–54% review xấu dù đúng hạn. Nên gom hàng và giao một lần, hoặc thông báo rõ cho khách là đơn sẽ về thành nhiều đợt.
4. **Mục tiêu khả thi:** muốn đưa tỷ lệ review xấu toàn quốc về $\leq 11\%$, cần giảm 58% số đơn trễ (tỷ lệ trễ 6,7% $\rightarrow$ 2,8%). Mức dưới 9,6% không thể đạt được chỉ bằng cải thiện giao hàng.

Các giả định của DSS cần nêu rõ khi trình bày:

1. Giao trễ là **nguyên nhân** gây review xấu (thực tế còn chất lượng sản phẩm, đóng gói…).
2. Đơn trễ sau khi được sửa sẽ đến **đúng ngày dự kiến**.
3. Tỷ lệ review xấu thực tế của mỗi lá cây (tập train) được dùng làm **xác suất** review xấu của đơn rơi vào lá đó.
4. Hai tham số chi phí `surcharge` và `tier`.

Chương 5. Đánh giá

5.1 Mức độ đáp ứng yêu cầu bài tập lớn

Bảng 5.1: Đối chiếu với sáu mục tiêu (§1.1 của đề)

#	Yêu cầu	Đáp ứng	Chương / Mục
1	Phân tích yêu cầu nghiệp vụ, xác định bài toán	Bài toán giao trễ → review xấu; câu hỏi phân tích và câu hỏi quyết định; data profiling	Chương 1
2	Thiết kế DW đa chiều (star / snowflake) + ETL	Fact constellation (2 fact dạng star dùng chung 4 dimension), grain, hierarchy; ETL và metadata; hợp đồng nguồn và kiểm tra chất lượng	Chương 2, Mục 3.4
3	Hiện thực backend (CSDL, ETL, OLAP) + frontend	PostgreSQL, ETL tự động, ROLAP + materialized views; dashboard Streamlit 5 trang (Home, OLAP, Delivery, DSS, Data Quality)	Chương 3
4	Phát triển thành phần DSS dựa trên DW	Hybrid DSS: cây quyết định, what-if, sensitivity, goal seeking, xếp hạng, tối ưu ngân sách (MILP) và phân tích độ vững, đề xuất	Chương 4
5	Đánh giá kết quả, hạn chế, hướng phát triển	43 kiểm tra chất lượng, 102 test tự động, metrics mô hình, cross-validation chọn tham số, kiểm tra mô hình rủi ro trên tập test, độ nhạy theo giả định chi phí, hạn chế, hướng phát triển	Chương 3–5
6	Trình bày trước lớp / video	Slide và video	**[TODO]**

Bảng 5.2: Đối chiếu chuẩn đầu ra (§1.2 của đề)

Chuẩn đầu ra	Nội dung	Vị trí trong báo cáo
L.O.1.1	Khái niệm cơ bản DW & DSS	Chương 2 (mở đầu), Mục 4.1
L.O.1.2	Vai trò của DW trong DSS	Mục 4.2
L.O.1.3	Ví dụ thực tế DW & DSS	Mục 5.4 và chính project này
L.O.2.1	Quy trình, nguyên lý thiết kế DW	Chương 2
L.O.2.2	Các vấn đề trong thiết kế DW	Mục 1.5 (chất lượng dữ liệu), granularity, partition, index, metadata (Chương 2), Mục 3.4 (kiểm soát chất lượng)
L.O.2.3	Thiết kế và hiện thực hệ thống DW	Chương 2, 3
L.O.3.1	Khái niệm, đặc tính MSS & DSS	Mục 4.1, 4.2
L.O.3.2	Các giai đoạn ra quyết định	Ánh xạ pha Simon (Mục 4.2)
L.O.3.3	Minh hoạ mô hình hoá trong DSS	Mục 4.3–4.5.5
L.O.4.1	Nguyên tắc phân tích, thiết kế DSS	Mục 4.2, Mục 1.7 (prototyping)
L.O.4.2	Phân tích, thiết kế, hiện thực DSS đơn giản	Chương 4

Bảng 5.3: Thành phần nộp (§5.1 của đề)

Thành phần	Trạng thái
Báo cáo PDF	Bản này (draft)
Mã nguồn `src/` (SQL, Python, frontend, ETL) – GitHub	`https://github.com/taita2005/co4031-olist-dw-dss`
Dữ liệu mẫu `data/`	**[TODO]** link Google Drive chứa CSV (GitHub không chứa CSV)
Slide PDF	**[TODO]**
Link video trên trang bìa	**[TODO]** nếu thuyết trình qua video

5.2 Hạn chế

Hạn chế	Ảnh hưởng
Dữ liệu chỉ 2016–2018; các tháng đầu / cuối rất ít đơn	Không phản ánh hiện tại; dashboard phải lọc tháng
97% khách chỉ mua 1 lần (2.997 / 96.096 khách mua $>$ 1 lần)	Không phân tích được hành vi mua lặp
Review xấu còn nhiều nguyên nhân ngoài giao hàng	Precision của mô hình thấp (32,9%)
What-if giả định giao trễ là **nguyên nhân** của review xấu (mô hình dựa trên tương quan)	Kết quả là ước lượng, cần kiểm chứng bằng thử nghiệm thực tế
"Sửa đơn trễ" được giả định là giao đúng ngày dự kiến	Chưa mô hình hoá được cách sửa cụ thể (đổi hãng, thêm kho…)
Chi phí trong tối ưu ngân sách dựa trên 2 giả định (`surcharge`, `tier`), vì Olist không có dữ liệu chi phí can thiệp	Mức giảm cụ thể ở mỗi bang phụ thuộc giả định; chỉ thứ tự ưu tiên là vững
ETL dạng full refresh, chưa incremental	Chưa phù hợp với dữ liệu phát sinh liên tục
Chưa dùng SCD (khách đổi địa chỉ chỉ giữ địa chỉ của đơn gần nhất)	Mất lịch sử thay đổi địa chỉ
Chưa dùng geolocation, chưa có bản đồ	Chưa phân tích được theo khoảng cách địa lý
Một số bang có rất ít đơn (RR 41, AP 67, AC 80)	Tỷ lệ ở các bang này kém tin cậy

5.3 Hướng phát triển

1. **Incremental ETL** (nạp theo ngày, dùng `etl_log` để biết lần nạp gần nhất) và **SCD type 2** cho dim_customer / dim_seller.
2. **Bản đồ địa lý** từ bảng geolocation (lấy toạ độ trung bình theo zip); thêm thuộc tính khoảng cách người bán – khách.
3. **Thay giả định chi phí bằng dữ liệu thật** (báo giá của hãng vận chuyển theo tuyến). Khi đó có thể mở rộng mô hình tối ưu ở Mục 4.5.5 từ chọn bang sang **chọn đơn vị vận chuyển cho từng tuyến** (người bán $\rightarrow$ người mua).
4. **Dự báo nhu cầu** theo tháng để chuẩn bị năng lực vận chuyển cho các đợt cao điểm như Black Friday (11/2017).
5. Dùng **comment review** (văn bản) để tách các nguyên nhân review xấu không liên quan đến giao hàng.

5.4 Ví dụ thực tế về DW & DSS (L.O.1.3)

[TODO] Nhóm tự bổ sung 2–3 ví dụ doanh nghiệp có **trích nguồn**, ví dụ:

- kho dữ liệu bán lẻ dùng cho quyết định nhập hàng (nhóm tự chọn doanh nghiệp và tìm nguồn);
- DSS tối ưu tuyến giao hàng của doanh nghiệp logistics (ví dụ P&G dùng mô hình vận tải và mô hình chọn vị trí trung tâm phân phối, có trong slide Ch.7);
- DSS phân tích khách hàng trong ngân hàng / viễn thông.

Liên hệ với project: Olist là trường hợp thực tế, gồm DW tích hợp dữ liệu đơn hàng và DSS hỗ trợ quyết định logistics.

5.5 Kết luận

Nhóm đã xây dựng hoàn chỉnh một hệ thống gồm:

1. **Kho dữ liệu** dạng fact constellation trên dữ liệu thật khoảng 100k đơn hàng. Quy trình ETL tự động có metadata, hợp đồng nguồn và 43 kiểm tra chất lượng sau mỗi lần nạp.
2. **Dashboard OLAP** minh hoạ đủ 5 phép toán trên 2 fact dùng chung dimension, cùng trang theo dõi chất lượng dữ liệu.
3. **DSS** kết hợp dữ liệu và mô hình. DSS chỉ ra được:
   - giao trễ là yếu tố quyết định review xấu (trễ trên 5 ngày $\rightarrow$ khoảng 80% review xấu);
   - đơn nhiều người bán là nguồn rủi ro thứ hai;
   - với ngân sách giới hạn, nên ưu tiên **RJ, GO, PR, RN**. Thứ tự này đúng trong ít nhất 4/6 bộ giả định chi phí. Ngân sách 40.000 BRL (giả định mặc định) đưa tỷ lệ review xấu kỳ vọng từ 12,85% xuống 11,38%;
   - muốn tỷ lệ review xấu $\leq$ 11% cần giảm 58% đơn trễ, còn dưới 9,6% thì logistics không giải quyết được.

Hệ thống đi đủ các pha ra quyết định của Simon, từ phát hiện vấn đề (intelligence) đến đề xuất hành động (implementation) và đánh giá (evaluation).

Tài liệu tham khảo

[1] W. H. Inmon, *Building the Data Warehouse*, 4th ed. Wiley, 2005.

[2] R. Kimball, M. Ross, *The Data Warehouse Toolkit*, 3rd ed. Wiley, 2013.

[3] E. Turban, J. E. Aronson, T.-P. Liang, *Decision Support Systems and Intelligent Systems*, 7th ed. Prentice-Hall, 2005.

[4] R. Elmasri, S. B. Navathe, *Fundamentals of Database Systems*, 7th ed. Addison-Wesley, 2016.

[5] R. Sharda, D. Delen, E. Turban, *Analytics, Data Science, & Artificial Intelligence: Systems for Decision Support*, 7th ed. Pearson, 2020.

[6] J. Han, M. Kamber, J. Pei, *Data Mining: Concepts and Techniques*, 3rd ed. Morgan Kaufmann, 2012.

[7] F. Burstein, C. W. Holsapple, *Handbook on Decision Support Systems*. Springer, 2008.

[8] Trần Minh Quang et al., *Cơ sở dữ liệu: khái niệm, phương pháp, và kỹ thuật phân tích thiết kế*. NXB ĐHQG-HCM, 2025.

[9] Olist, *Brazilian E-Commerce Public Dataset by Olist*, Kaggle. `https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce`

[10] Slide bài giảng CO4031 HK261, Chương 1–8, giảng viên Đỗ Thanh Thái.

[11] Tài liệu PostgreSQL 16, scikit-learn 1.5, Streamlit 1.39, SciPy (HiGHS).

Chương A. Hướng dẫn cài đặt và chạy

Chi tiết xem `README.md` mục 1. Tóm tắt:

```
git clone https://github.com/taita2005/co4031-olist-dw-dss.git BTL
cd BTL
# đặt CSV Olist vào data/ (xem data/README.md)
bash scripts/setup_env.sh        # cài môi trường cục bộ (lần đầu)
source scripts/env.sh
bash scripts/db_start.sh         # PostgreSQL cục bộ, port 5433
python src/etl/run_etl.py        # ETL + 43 kiểm tra (~12 giây)
python src/dss/train_model.py    # train mô hình (~25 giây)
streamlit run src/app/Home.py    # http://localhost:8501
python -m pytest tests -q        # 102 test
bash scripts/db_stop.sh
```

Tuỳ chọn chạy bằng Docker Compose và Metabase: xem `docs/metabase.md`.

Chương B. Cấu trúc mã nguồn

Đường dẫn	Vai trò
scripts/	Cài môi trường, bật / tắt PostgreSQL cục bộ; script cho Docker và Metabase
environment.yml	Danh sách package
src/db.py	Kết nối CSDL dùng chung
src/sql/01_staging.sql	Tạo bảng staging
src/sql/02_dw_schema.sql	Tạo dimension, fact, index, partition, meta.etl_log
src/sql/03_transform_load.sql	Toàn bộ logic Transform + Load
src/sql/04_olap_views.sql	Materialized views
src/sql/05_checks.sql	27 kiểm tra chất lượng trên DW → meta.check_result
src/sql/06_bi_views.sql	View bi cho Metabase (tuỳ chọn), chỉ trả dữ liệu khi mọi kiểm tra đạt
src/etl/contracts.py	Hợp đồng nguồn: kiểm tra từng CSV trước khi nạp
src/etl/run_etl.py	Điều phối ETL, ghi metadata và kết quả kiểm tra
src/dss/train_model.py	Huấn luyện cây quyết định, trích luật, tính information gain, thực nghiệm tham số, tính trước lợi ích cho tối ưu
src/dss/whatif.py	What-if, sensitivity, goal seeking, xếp hạng
src/dss/optimizer.py	Tối ưu ngân sách (MILP + greedy baseline), độ nhạy theo tier, phân tích độ vững
config/cost_assumptions.csv	2 giả định chi phí, kèm giải thích ở config/README.md
src/app/Home.py, src/app/pages/*.py	5 trang dashboard
tests/	102 test (pytest)
models/	(sinh ra) model, luật, metrics, experiments.json, options.csv
compose.yml, docs/metabase.md	Tuỳ chọn: chạy toàn bộ stack bằng Docker Compose, kèm 3 dashboard Metabase

Chương C. Danh sách đầy đủ 43 kiểm tra chất lượng

Kết quả lần chạy ngày 14/11/2026: tất cả đều đạt.

#	Nhóm	Kiểm tra
1	grain	fact_sales: không trùng (order_id, order_item_id)
2	grain	fact_delivery: không trùng order_id
3	grain	dim_customer: không trùng customer_unique_id
4	reconciliation	Số dòng: staging.order_items = fact_sales
5	reconciliation	SUM(price): staging.order_items = fact_sales
6	reconciliation	SUM(freight_value): staging.order_items = fact_sales
7	reconciliation	Số dòng: đơn delivered có ngày giao = fact_delivery
8	reconciliation	SUM(order_value): item của đơn delivered = fact_delivery
9	reconciliation	Số đơn trễ: staging = SUM(fact_delivery.is_late)
10	reconciliation	Đơn delivered có review = số dòng fact_delivery có review_score
11	reconciliation	Số dòng: số customer_unique_id khác nhau = dim_customer
12	reconciliation	Số dòng: staging.sellers = dim_seller
13	reconciliation	Số dòng: staging.products = dim_product
14	domain	review_score nằm ngoài 1..5
15	domain	is_bad_review không nhất quán với review_score ≤ 2
16	domain	is_late không nhất quán với delay_days > 0
17	domain	delay_days $\neq$ delivery_days $-$ estimated_days
18	domain	delivery_days hoặc estimated_days âm
19	domain	price ≤ 0 hoặc freight_value < 0
20	domain	total_value $\neq$ price + freight_value
21	coverage	Ngày mua / giao trong nguồn nằm ngoài dim_date
22	coverage	Sản phẩm có danh mục nguồn nhưng không có tên tiếng Anh
23	coverage	Khách / người bán có bang nhưng không có vùng
24	aggregate	Tổng của mv_sales_cube = fact_sales (loại canceled / unavailable)
25	aggregate	SUM(mv_monthly_kpi.revenue) = fact_sales (loại canceled / unavailable)
26	aggregate	SUM(mv_delivery_by_state.n_orders) = fact_delivery
27	aggregate	Các tỷ lệ trong materialized view nằm ngoài [0, 1]

#	Nhóm	Kiểm tra
28–43	source	Với mỗi file trong 8 CSV (orders, order_items, order_payments, order_reviews, customers, sellers, products, category_translation): (a) không vi phạm hợp đồng nguồn; (b) số dòng CSV = số dòng bảng staging tương ứng

Chương D. Thay đổi so với proposal ban đầu

Xem bảng "Thay đổi so với bản đề xuất ban đầu" trong `docs/proposal.md`. Tóm tắt:

- dùng môi trường micromamba thay cho Docker (Docker Compose được bổ sung sau như một tuỳ chọn);
- thêm `product_key` và `n_sellers` vào `fact_delivery`;
- metadata đặt ở schema `meta`;
- đã làm partition;
- xác suất lấy theo lá của cây;
- goal seeking dùng complete enumeration;
- phân công đổi thành 1 người code, 2 người review;
- bổ sung sau proposal: hợp đồng nguồn và kiểm tra chất lượng tự động, trang Data Quality, thực nghiệm chọn tham số bằng cross-validation, tối ưu ngân sách (MILP) cùng phân tích độ vững, và phần mở rộng Docker Compose + Metabase.

Chương E. Danh sách hình cần chụp

#	Hình	Vị trí
1	ERD dữ liệu nguồn	Mục 1.5
2	Sơ đồ kiến trúc 3 tầng	Mục 3.1
3	Sơ đồ schema fact constellation	Chương 2
4	Luồng ETL (staging → dw → meta)	Mục 2.6
5	Trang Home (KPI + xu hướng)	Chương 3
6–10	OLAP: roll-up, drill-down, slice, dice, pivot	Mục 3.6.1
11	OLAP: mục “SQL được sinh ra”	Mục 3.6.1
12	OLAP: chọn fact_delivery (ghi chú non-additive)	Mục 3.6.1
13	Trang Delivery	Chương 3
14–17	DSS: tab mô hình, xếp hạng, what-if + sensitivity, goal seeking	Chương 4
18	Goal seeking trường hợp không khả thi (mục tiêu 9,5%)	Chương 4
19	DSS tab 5: bảng ưu tiên vững qua 6 bộ giả định	Mục 4.5.5
20	DSS tab 5: phương án chi tiết 40.000 BRL + đường cong ngân sách – lợi ích	Mục 4.5.5
21	DSS tab 1: bảng thực nghiệm chọn tham số	Mục 4.3
22	Trang Data Quality	Mục 3.4